

GRPO 后训练：让 VLM 学会数数、让 VLA 自我提升

目录

1 从 PPO 到 GRPO：为什么不再请评分员	4
1.1 回顾上一讲：PPO 手里的四件家当	4
1.2 场景变了：从 G1 行走到大模型答题	4
1.3 critic 的账算不过来	5
1.4 GRPO 的一招：同题采一组，平均分当基线	5
1.5 留下的没变：clip 还在，再加一条对参考模型的 KL	6
1.6 本节小结	7
2 可验证奖励，和一个题眼	7
2.1 奖励从哪来	7
2.2 稀疏，但干净	7
2.3 题眼：强化学习外环与策略本体解耦	8
2.4 本节小结	9
3 VLM 后训练：从 DeepSeek-R1 到会数数的小模型	9
3.1 R1 时刻	9
3.2 搬到多模态：R1-V 与 Visual-RFT	9
3.3 为什么数数是最干净的入门	10
3.4 本节小结	11
4 实验：让 VLM 学会数数	11
4.1 任务与设置	11
4.2 奖励：两条判分规则	11
4.3 结果：从蒙到数	12
4.4 本节小结	12
5 VLA 后训练：把「答对没」换成「干成没」	13
5.1 机器人任务天然可验证	13
5.2 三个层次的代表工作	13
5.3 本课载体：VLA-0，动作即整数文本	13

5.4 SFT 基线为什么重要	14
5.5 本节小结	14
6 SimpleVLA-RL: 把 GRPO 搬上 VLA 的代表作	15
6.1 背景与动机	15
6.1.1 SFT 的两大瓶颈	15
6.1.2 从 LLM RL 到 VLA RL 的启发	16
6.1.3 SimpleVLA-RL 的核心定位	16
6.2 预备知识: LLM RL vs VLA RL	16
6.2.1 LLM 的 RL 形式化	16
6.2.2 VLA 的 RL 形式化	17
6.2.3 核心差异	17
6.2.4 GRPO 目标函数: 把第 1 节的直觉写完整	17
6.3 SimpleVLA-RL 方法	18
6.3.1 总体框架	18
6.3.2 交互式 VLA Rollout	19
6.3.3 结果奖励建模	19
6.3.4 探索增强策略	19
6.3.5 训练目标	20
6.4 实验结果与讨论	21
6.4.1 主要结果: RL 把 SFT 的上限继续往上推	21
6.4.2 数据效率: RL 可以弥补示教数据不足	22
6.4.3 泛化: RL 不只是记住训练任务	22
6.4.4 Sim-to-Real: 仿真 RL 的收益能迁移到真实世界	23
6.4.5 行为变化: “Pushcut” 说明 RL 在优化任务结果	24
6.4.6 失败边界: RL 需要最低初始能力	24
6.5 局限性与未来方向	25
6.6 本节小结	25
7 RLinf: VLA 强化学习的基建化	26
7.1 为什么需要基建	26
7.2 一套接口, 三种编排	27
7.3 对本讲的启示	28
7.4 本节小结	28
8 实验: 让 VLA-0 自我提升成功率	28
8.1 动手之前: 先量提升空间	28
8.2 训练循环: 把数数的外壳搬过来	28
8.3 第一道坎: 组里没有信号	29
8.4 第二道坎: 学了这个忘那个	30
8.5 第三道坎: 越训越差	30

8.6 结果：涨点、对照与早停	30
8.7 本节小结	32
9 $\pi_{0.6}^*$：让 VLA 从真实经验中学习	32
9.1 背景与动机	33
9.1.1 从模仿学习到经验学习	33
9.1.2 VLA 强化学习的挑战	33
9.1.3 RECAP 的核心思路	34
9.2 从正则化强化学习到 Advantage Conditioning	34
9.2.1 问题设定	34
9.2.2 正则化强化学习	35
9.2.3 从闭式解到 Advantage Conditioning	36
9.3 RECAP 方法详解	38
9.3.1 分布式价值函数训练	38
9.3.2 Advantage 条件化策略训练	41
9.3.3 推理时的策略改进：Classifier-Free Guidance	43
9.3.4 完整算法流程	44
9.4 与其他策略提取方法的对比	44
9.4.1 为什么不用 PPO	44
9.4.2 为什么不用 AWR	45
9.4.3 实验对比	45
9.5 实验结果	45
9.5.1 评估任务	45
9.5.2 主要结果	46
9.6 RECAP 与本讲方法的关系	47
9.6.1 在课程体系中的位置	47
9.6.2 与 Reward Conditioning 文献的关系	47
9.7 本节小结	48
10 本讲小结	48
10.1 一套外壳，两个载体	48
10.2 一条越走越宽的路	49
参考资料	49

1 从 PPO 到 GRPO：为什么不再请评分员

1.1 回顾上一讲：PPO 手里的四件家当

上一讲我们从最朴素的策略梯度出发，一路把 G1 的行走策略升级到了 PPO。先盘点一下 PPO 手里的家当：

部件	作用
策略网络 (actor)	从观测映到动作分布，是我们真正要的东西
价值网络 (critic)	给每个状态估计”从这里出发平均还能拿多少回报”，充当基线
GAE	把多步实际回报和价值估计折中，进一步压方差
clip 目标	限制每次更新的步子，防止策略一步迈进深渊

其中 critic 是我们花钱请来的”评分员”：策略梯度告诉我们”好动作加概率、坏动作减概率”，但”好坏”必须跟一个参照比才有意义，critic 提供的就是这个参照。它和策略一起训练、一起长大，是降低方差的关键。

上一讲结尾我们留了一个问题：这位花钱请来的评分员，有没有可能不请？本讲的第一件事就是回答它。

1.2 场景变了：从 G1 行走到大模型答题

在回答之前，先看清场景发生了什么变化。上一讲的 RL 用来从零训练一个行走策略；本讲的 RL 用在一个已经预训练、微调过的大模型上，让它在某个指标上继续变好——这个阶段叫**后训练 (post-training)**。两个场景的差别比看上去大得多：

维度	G1 学走路	大模型答题
策略本体	几百万参数的小网络	3B 起步的大模型
一个回合	仿真里走几千步	生成一段回答，生成完即回合结束
奖励	每一步都有（速度、姿态、能耗）	只在句末（答对 / 答错）
同一初始状态重复	不同回合初始状态各不相同	同一道题可以让模型答任意多遍

这张表读出三个含义：

- 1. **奖励全堆在末尾**。生成中途没有任何奖励，GAE 那套”多步回报折中”没了用武之地；
- 2. **critic 变得极其昂贵**。要估计”从这半截回答出发还能得多少分”，critic 得读懂这半截回答——它必须是一个和策略同体量的大模型；
- 3. **但答题场景有一个 G1 行走没有的便利**：同一道题，可以让模型答很多遍。

第三条正是 GRPO 的突破口。

1.3 critic 的账算不过来

先把第二条展开。如果照搬 PPO 去后训练一个 7B 模型，显存里要同时放下：7B 的策略、7B 的 critic、再加一个冻结的参考模型——训练开销直接翻倍以上。

更麻烦的是 critic 很难训准。奖励只在句末出现，critic 要从”半截文本”预测最终得分，这个回归问题本身就极难；而一个估不准的基线比没有基线更糟——它会系统性地把梯度引向错误的方向。DeepSeek 团队在数学推理任务上的实践正是被这两个问题逼出了新招。

1.4 GRPO 的一招：同题采一组，平均分当基线

既然同一道题可以答很多遍，那全组的平均分就是现成的基线——不用请评分员，让这组回答互相比就行了。

具体做法：对同一个题目 (prompt)，用当前策略采样 G 条回答，逐条用规则打分得到奖励 $r_1, r_2, \dots, r_G$ ，然后把每条回答的优势定义为组内标准化的相对分数：

$$\hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}$$

符号	含义	典型取值
G	同一题目采样的回答条数（组大小）	4 ~ 16
r_i	第 i 条回答的奖励	0 或 1（规则判定）
$\hat{A}_i$	第 i 条回答的组相对优势	正 = 比组平均好，负 = 比组平均差

比组平均好的回答，整条的所有 token 都被加概率；比组平均差的，整条减概率。critic 的活——提供”平均水平”这个参照——被一次分组采样直接干掉了。

备注：组内标准化给出的只是**相对**优势——每条回答是跟”这一组的平均”比，而不是跟一个绝对的价值估计比。软肋也正在这里：万一一组里的回答全对或全错，组内没有差异，标准化后优势全为零，这一组就不产生任何梯度。所以 GRPO 格外依赖”组里有对有错”的题目；第 6、8 节里调采样温度、做动态采样，很大程度上就是在保证每组内部有信号可比。




图 1: PPO 与 GRPO 的训练管线对比: PPO 需要与策略同体量的价值模型参与优势估计; GRPO 去掉价值模型, 对同一题目采样一组输出, 用组内相对分数直接得到每条输出的优势

上图出自提出 GRPO 的 DeepSeekMath 论文, 上下两行值得对着读: 上半行 PPO, policy 与 value 两个大模型都要训练, GAE 把奖励与价值汇合成优势; 下半行 GRPO, value model 整块消失, 取而代之的是“Group Computation”——同一题目的 G 条输出各拿一个奖励, 组内归一化后直接得到每条的优势。GRPO 在 DeepSeekMath 中提出, 随后被 DeepSeek-R1 发扬光大, 成为大模型后训练的主力算法之一。

1.5 留下的没变: clip 还在, 再加一条对参考模型的 KL

GRPO 是对 PPO 做减法, 而不是推翻重来。上一讲管住策略的两件事, 一件原样保留、一件是新增:

- **clip 照旧**: 组相对优势 $\hat{A}_i$ 直接代入 PPO 的 clip 目标, 每次更新的步子仍被概率比值的裁剪范围限制。要强调的是——把新策略拉回旧策略附近 (单步的信赖域) 这件事, 仍然由 clip 承担, 并没有随 GRPO 而消失。
- **新增一条对参考模型的 KL**: GRPO 额外挂一条 KL, 约束“策略别偏离参考模型 (通常是 RL 开始前的 SFT 模型) 太远”, 管的是整场训练不要把模型带离原本的胜任区。它是加上去的锚, 不是把 clip 那条旧策略约束”搬了个家”。

备注: 别把这条 KL 和上一讲 PPO 里的 KL 混了。上一讲 PPO 也量新旧策略的 KL, 但那只是用来自适应调学习率的旁路, 真正约束单步步长的是 clip; GRPO 新增的这条 KL 则全程锚定在同一个冻结的参考模型上, 防的是“训着训着整个人变了”。一个盯”这一步迈太大” (clip)、一个盯”整场训练跑偏” (KL 锚) ——两件事各管各的。本讲第 8 节的实验会让你亲眼看到这条 KL 锚有多重要。

完整的 GRPO 目标函数我们放到第 6 节讲 SimpleVLA-RL 时给出——那里正好第一次真正用到它。

1.6 本节小结

GRPO 用” 同题采一组、组内平均分当基线” 替掉了 PPO 的价值网络，把后训练大模型的显存和训练难度砍掉一半；clip 护栏保留（旧策略的信赖域仍靠它），另加一条对参考模型的 KL 锚定整场训练。它的代价是要求” 同一初始状态可以重复采样”——这在答题场景免费，在机器人场景则需要仿真器配合，这个伏笔后面会兑现。还没回答的问题是：句末那个奖励从哪来？这是下一节的主题。

2 可验证奖励，和一个题眼

2.1 奖励从哪来

GRPO 把” 怎么算优势” 解决了，但每条回答的分数 r_i 从哪来？后训练大模型有三条路：

路线	做法	毛病
人工打分	每条回答请人评	无法规模化，采样一批就要标一批
训练奖励模型	先用人标偏好训一个打分模型，再让它代人打分	要先烧一轮标注；策略会学会” 讨好” 打分模型而非真的变好
规则判定	用确定性规则直接判对错	只适用于答案可机判的任务

第三条路就是**可验证奖励**（RLVR，Reinforcement Learning with Verifiable Rewards）：数学题比对最终答案、代码跑测试用例、机器人任务看有没有完成——奖励函数退化成一段判分脚本。

2.2 稀疏，但干净

可验证奖励通常是 0/1 的稀疏信号：对就是对，错就是错，中间过程一分不给。看起来信息量很少，但它有两个训练奖励模型换不来的性质：

- **干净**：判分规则没有参数、不会被” 黑”。策略找不到” 骗过打分器” 的捷径，只能真的把任务做对；
- **免费且无限**：判分脚本可以自动运行任意多次，采样多少条就能判多少条，成本不随规模增长。

而且稀疏奖励和 GRPO 天然般配：同一道题采 G 条回答，只要有对有错，组内立刻分出高下，0/1 奖励经过组内标准化就变成了有正有负的密集学习信号。




图 2: 多模态 GRPO 训练管线: 策略对同一输入采样多条带推理过程的回答, 可验证奖励 (如检测的 IoU、分类的正确性) 逐条打分, 组内比较后更新策略

上图是 Visual-RFT 论文给出的管线图, 可以当作“GRPO + 可验证奖励”组合拳的标准照: 左边同一张图配同一个问题, 策略采样出多条回答; 中间每条回答被规则函数打分; 右边组内比较出优势、回传更新。整个环路里没有价值网络, 也没有奖励模型。

2.3 题眼：强化学习外环与策略本体解耦

现在把这个训练环路从头到尾盘一遍, 数一数它对“策略”这个黑盒到底提了几个要求:

1. 给定输入, 能采样出一串离散 token;
2. 对采出的每个 token, 能给出它的 **log 概率** $\log \pi_\theta$ (用来算概率比值和 KL);
3. 外环拿到完整输出后能**判分**。

就这三条。环路完全不关心 token 的**含义**——它是一个中文字、一个数学符号, 还是别的什么, GRPO 一概不问。

这就是本讲的题眼: **强化学习外环和策略本体是解耦的**。语言模型输出文本 token; 而有一类 VLA 模型 (比如后面会反复出现的 VLA-0) 把机器人动作离散成整数、当成文本打出来——动作 token 和文本 token 在数学上是同一个东西: 都是大模型词表上的 categorical 分布, log 概率的算法一模一样。

于是一个大胆的推论自然成立: **给 VLM 做数数后训练的那套 GRPO 外壳, 几乎一行不改, 就能套到 VLA 的动作 token 上**——只要把“答案对不对”的判分脚本换成“任务成没成”的仿真判定。本讲的两个实验就是沿这条线展开的。

反过来，这个题眼也划出了边界：如果动作头不是离散 token，而是 flow matching 或扩散模型输出的连续动作，第 2 条要求（干净的 log 概率）就不满足，这套外壳套不上去。怎么办？第 9 节的 $\pi_{0.6}^*$ 会给出一条绕行的路，下一讲的价值方法则是另一条正面解决的路。

2.4 本节小结

可验证奖励用判分脚本替掉了人工标注和奖励模型，稀疏但干净，和 GRPO 的组内比较天然互补。更重要的是我们看清了 GRPO 外环对策略只有“离散选择 + log 概率”两个要求——文本 token 与离散动作 token 因此可以共用同一套后训练外壳。这个题眼是本讲把 VLM 和 VLA 并在一起讲的全部理由。

3 VLM 后训练：从 DeepSeek-R1 到会数数的小模型

3.1 R1 时刻

把 GRPO 和可验证奖励组合起来大规模应用的标志性工作是 DeepSeek-R1：在数学和代码这两类天然可机判的任务上做 RLVR 后训练，模型的逐步推理能力随训练显著涌现，重新定义了“后训练”在大模型训练管线里的地位。R1 的细节不是本讲重点，只需要记住它验证的这条配方：**规则奖励 + GRPO**，就足以让大模型学会一类新能力。

3.2 搬到多模态：R1-V 与 Visual-RFT

这条配方很快被搬到了视觉-语言模型上。R1-V 项目在 SuperCLEVR 数数任务上后训练 Qwen2-VL-2B，训练成本不到 3 美元，数数准确率超过了 72B 的同系大模型；Visual-RFT 则系统地把 R1 式的后训练扩展到检测、分类、定位等一系列视觉任务——检测框的 IoU、分类的对错，都可以写成判分规则。




图 3: 视觉指令微调与视觉强化微调的对比：指令微调依赖大量标注数据教模型模仿；强化微调只需少量样本，用可验证奖励驱动模型自己试错变好

上图 (Visual-RFT) 把两种范式画在了一起：左边是传统视觉指令微调，本质是记忆式模仿，数据饥渴；右边是可验证奖励驱动的强化微调，模型对每个输入生成多条带推理的回答，靠规则反馈自我修正，几十到几百条样本就能显著提升。对小模型、垂直任务来说，右边这条路的性价比高得多。

3.3 为什么数数是最干净的入门

在所有视觉 RLVR 任务里，我们选**数数**作为第一个上手实验，因为它把无关变量压到了最少：

- **答案唯一且是整数**：“图里有几个红色的球”只有一个正确答案，判断就是字符串比对，零歧义；
- **不需要奖励模型、不需要人**：规则一行就能写完；
- **不需要机器人**：纯计算任务，单卡就能完整跑通训练加评测；
- **能力真实有用**：数数考验的是视觉定位加逐个枚举，恰是小 VLM 普遍薄弱、又能被 RL 明显改善的能力。

下一节我们就在这个任务上，完整跑一遍”后训练前 → 后训练后”的对照。

3.4 本节小结

DeepSeek-R1 验证了”规则奖励 + GRPO”的后训练配方，R1-V 和 Visual-RFT 证明它能以极低成本搬到多模态模型上。数数任务判分零歧义、不需要机器人，是视觉 RLVR 的最干净入门，也是我们第一个实验的舞台。

4 实验：让 VLM 学会数数

4.1 任务与设置

第一个实验完整复刻上一节的配方：在 SuperCLEVR 数数任务上，用 GRPO 后训练一个小型视觉-语言模型，看它从”数不对”到”数得对”。SuperCLEVR 是渲染出来的 3D 场景数据集，图里散落着不同颜色、形状、材质的物体，问题形如”图中有几个红色的金属物体”，答案是一个整数。

设置项	取值
基座模型	Qwen2.5-VL-3B-Instruct (LoRA 微调)
训练算法	GRPO (TRL 库的 GRPOTrainer)
训练数据	CLEVR 计数题 512 条 (R1-V 项目同款)
组大小 G	4
训练步数	300 步，单卡，总用时约 22 分钟
评测	SuperCLEVR 固定 200 题切片，训练前后同一套题

备注：更小的 Qwen2-VL-2B 与当前训练工具链存在兼容问题，因此选用 3B。完整的训练与评测代码将随课程代码一并发布，课堂演示以本节的设置与结果为准。

4.2 奖励：两条判分规则

整个实验的奖励函数只有两条规则，都能用几行判分逻辑写完：

- **格式奖励**：回答必须把最终答案放进规定的标签里（形如 `<answer>7</answer>`）。守规矩得分，否则不得分；
- **正确性奖励**：从标签里抽出的答案与标准答案一致，得 1 分，否则 0 分。

为什么需要第一条？如果答案埋在自由发挥的文本里，判分脚本就抓不准它，正确性奖励无从谈起。格式奖励每条回答都能判、信号密集，模型很快学会”把答案放在指定位置”；在此基础上，稀疏的正确性奖励才有的放矢。先教格式、再提准确率，这是 DeepSeek-R1 以来 RLVR 训练的通用小技巧。

4.3 结果：从蒙到数

训练前后在同一套 200 题上各评一遍：

指标	后训练前	后训练后	提升
数数准确率	0.095	0.44	+0.345
答案格式合规率	0.22	0.79	+0.57




图 4: VLM 数数后训练前后对照：数数准确率从 0.095 提升到 0.44，答案格式合规率从 0.22 提升到 0.79（SuperCLEVR 固定 200 题）

后训练前的 3B 模型在 SuperCLEVR 上准确率只有 9.5%——基本处于“蒙”的水平；300 步 GRPO 之后达到 44%。格式合规率的涨幅更大（0.22 到 0.79），而且在训练中先于准确率上升：格式奖励密集、每条都能判，模型先学会守规矩，然后才在守规矩的基础上慢慢把数数得分做上去——两条奖励曲线的先后关系，恰好是“密集信号引路、稀疏信号定向”的直观教材。

诚实地说，44% 远不是这个任务的上限，更长的训练、更大的组还能继续涨。但作为演示，从 9.5% 到 44% 的跳变已经把要点说清楚了：**不加新数据、不加人工标注，只靠判分脚本和 GRPO，模型确实学会了一项它原本不会的能力。**

4.4 本节小结

用现成的 GRPO 训练器加两条判分规则，单卡二十来分钟就完成了一次完整的 RLVR 后训练，数数准确率从 0.095 提到 0.44。这个实验的全部要素——组采样、规则打分、组内比较——接下来会原封不

动地出现在 VLA 的后训练里，变的只有两样：策略的 token 从文字换成动作，判分从比对答案换成仿真器判定任务成败。

5 VLA 后训练：把「答对没」换成「干成没」

5.1 机器人任务天然可验证

把第 2 节的判分脚本从“答案比对”换成“任务判定”，可验证奖励就走进了机器人领域。仿真基准 LIBERO 里，每个任务自带成功判定——物体有没有被放到目标位置、抽屉有没有被拉开，仿真器一查便知。**机器人任务天生就是可验证奖励的富矿**：不用训奖励模型，不用人盯着打分。

仿真器还顺手兑现了第 1 节埋下的伏笔。GRPO 要求“同一道题答 G 遍”，机器人版的“同一道题”就是**同一个初始状态**——仿真器可以把场景精确重置到同一初始布局，让策略从完全相同的起点跑 G 条轨迹。真机上这两件事（自动判定、精确重置）都很难，所以本讲的 VLA 后训练全部在仿真里完成；真实世界的路怎么走，第 9 节和下一讲各给一条。

5.2 三个层次的代表工作

2025 年前后，VLA 强化学习后训练集中爆发。我们选三篇代表作，它们恰好回答三个不同层次的问题：

工作	层次	回答的问题
SimpleVLA-RL (第 6 节)	算法	GRPO 搬上 VLA 到底行不行、能涨多少
RLinf (第 7 节)	系统	大规模 VLA 强化学习的 GPU 资源怎么编排
$\pi_{0.6}^*$ (第 9 节)	落地	连续动作头、真实世界部署怎么办

本讲把三篇都过一遍：先看代表作怎么把路走通（第 6 节），再看基建怎么把路修宽（第 7 节），然后自己动手在单卡上复刻一个最小版（第 8 节），最后看前沿怎么把它推向真实世界（第 9 节）。

5.3 本课载体：VLA-0，动作即整数文本

第 11 讲的模型导览里我们见过 VLA-0：它对 VLM 零架构改装，直接把机器人动作离散成整数、按文本打印出来——“动作即文本”路线的极简代表。




图 5: VLA-0 的动作表示：机器人动作被离散化为整数序列，作为普通文本 token 由 VLM 直接生成，模型架构零改装

当时它是导览里的一个极简方案，现在轮到它当主角了。回到第 2 节的题眼——GRPO 外环只要求”离散选择 + log 概率”，逐项检查 VLA-0：

- 动作是整数文本 token，log 概率与文字完全同构，GRPO 外壳直接套；
- 模型只有 0.5B 参数量级的版本，单卡放得下训练和采样；
- 社区有现成的策略实现，SFT 起点唾手可得。

反观 π_0 、SmolVLA 这类 flow matching 动作头：动作是连续向量，没有干净的 log 概率，这套外壳套不上——它们的后训练要走第 9 节的绕行路线。选 VLA-0，是让”外壳不变、载体更换”这件事以最干净的方式发生。

5.4 SFT 基线为什么重要

动手之前还有最后一个概念要建立。稀疏 0/1 奖励下，GRPO 的学习信号来自”组内有对有错”：如果基座策略在任务上**从不成功**，每组 G 条轨迹全是 0 分，组内标准差为零、优势恒为零——**一步也学不动**。反过来，如果基座已经**接近满分**，组内全是 1 分，同样没有信号，而且也没有提升空间了。

所以 VLA 后训练开工前必须先量两个数：**基座成功率是不是大于零**（有没有信号）、**离天花板还有多远**（有没有提升空间）。最舒服的起点是成功率居中的基座——一组里既有成功又有失败，每次采样都带信息。这条规律看似朴素，第 6 节 SimpleVLA-RL 的失败边界实验和第 8 节我们自己的实验都会结实实撞上它。

5.5 本节小结

机器人仿真任务自带成功判定和精确重置，天然满足可验证奖励和 GRPO 分组采样的两个前提。三篇代表作分别站在算法、系统、落地三个层次上，本课的动手载体则选定”动作即整数文本”的 VLA-0

——log 概率与文本同构，数数实验的外壳可以原样搬来。唯一的新前提是基座成功率必须”不为零也不满分”，这个数字决定了后训练有没有得学、有没有得涨。

6 SimpleVLA-RL: 把 GRPO 搬上 VLA 的代表作

论文: *SimpleVLA-RL: Scaling VLA Training via Reinforcement Learning*, Tsinghua University & Shanghai AI Lab, 2025 (arXiv: 2509.09674)




图 6: SimpleVLA-RL 总览：基于 veRL 构建的高效 VLA 在线强化学习框架，通过交互式轨迹采样、结果奖励和探索增强策略，在仿真和真实世界任务中显著提升 VLA 性能

第 11、12 讲里我们认识的 π_0 、 $\pi_{0.5}$ 、SmolVLA，训练范式都是**监督微调 (SFT)**：用人类示教轨迹作为标签，让模型学习模仿。然而 SFT 面临两个根本性瓶颈：（1）高质量机器人轨迹数据稀缺且采集成本高昂；（2）模型泛化能力受限于训练数据的分布。

受 DeepSeek-R1 的启发——RL 仅凭结果奖励就能显著提升 LLM 的逐步推理能力——SimpleVLA-RL 提出了一个自然的问题：**RL 能否同样提升 VLA 模型的逐步动作规划能力？**

6.1 背景与动机

6.1.1 SFT 的两大瓶颈

当前 VLA 模型的主流训练范式是”大规模预训练 + SFT”，但在进一步扩展时遇到了两个核心挑战：

挑战	具体表现
数据	扩展 SFT 需要大量人类操作的机器人轨迹，但这些数据采集需要精心设计的实验场景、多样化的操作对象和熟练的操作员，成本极高且难以规模化
泛化	SFT 依赖有限的、场景和任务特定的数据，当 VLA 模型遇到未见过的任务、环境或物体
不足	时，性能不可避免地下降

6.1.2 从 LLM RL 到 VLA RL 的启发

DeepSeek-R1 证明了一个重要发现：仅使用简单的结果奖励（答案正确与否），RL 就能驱动 LLM 学会逐步推理。这启发了一个类比：

$$\underbrace{\text{LLM: 逐 token 推理}}_{\text{RL 提升推理链质量}} \longleftrightarrow \underbrace{\text{VLA: 逐步动作规划}}_{\text{RL 能否提升动作序列质量?}}$$

然而，将 RL 从 LLM 迁移到 VLA 并非简单的套用。两者在状态空间、动作空间、环境交互和 rollout 方式上存在根本差异，这正是 SimpleVLA-RL 需要解决的核心技术问题。

6.1.3 SimpleVLA-RL 的核心定位

SimpleVLA-RL 是一个面向 VLA 模型的高效在线 RL 框架，基于字节跳动的 veRL（一个通用 LLM RL 框架）构建。它的核心贡献是：

1. **将 LLM RL 框架适配到 VLA**：实现 VLA 特有的交互式轨迹采样和损失计算
2. **仅使用结果奖励**：任务成功为 1，失败为 0，无需手工设计过程奖励
3. **探索增强策略**：通过动态采样、调整裁剪范围和提高采样温度，显著提升 RL 训练效率
4. **发现新现象**：RL 训练中模型自主发现了示教数据中不存在的新策略（“pushcut”）

6.2 预备知识：LLM RL vs VLA RL

理解 SimpleVLA-RL 的关键在于看清 LLM 和 VLA 在 RL 框架下的本质差异。

6.2.1 LLM 的 RL 形式化

要素	定义
状态 s_t	输入 prompt 加上已生成的 token: $s_t = (x_{\text{prompt}}, y_1, \dots, y_{t-1})$
动作 a_t	从词表 $\mathcal{V}$ 中采样下一个 token: $a_t = y_t \sim \text{softmax}(f_\theta(s_t)/T)$
环境	序列生成完成后提供奖励信号（正确/错误，或学习的奖励模型）
Rollout	自回归生成 token 直到终止， 无需中间环境反馈

6.2.2 VLA 的 RL 形式化

要素	定义
状态 s_t	多模态观测: $s_t = (o_t^{\text{vis}}, o_t^{\text{prop}}, l_{\text{task}})$, 包括视觉输入、本体感知和语言指令
动作 a_t	机器人控制命令: $a_t \in \mathbb{R}^d$, 通过 action tokenizer 或 diffusion expert 生成
环境	物理世界或仿真器, 提供状态转移 $s_{t+1} = \text{Env}(s_t, a_t)$ 和奖励信号
Rollout	与环境持续交互, 每步执行动作后获取新观测, 需要闭环反馈

6.2.3 核心差异

两者最关键的差异在于 rollout 方式:

维度	LLM RL	VLA RL
Rollout 方式	一次性自回归生成完整序列	多轮与环境交互, 每步更新观测
环境反馈	仅在序列完成后	每步都有状态转移
动作空间	离散 token (词表)	连续控制命令或离散 action token
采样成本	低 (纯计算)	高 (需要渲染环境)
多样性来源	温度采样自然产生	需要特殊设计 (action decoder 类型依赖)

VLA 的 rollout 需要在每个时间步与环境交互——每个动作改变环境状态, 后续动作必须基于实时感知反馈。这使得 VLA RL 的采样成本远高于 LLM RL, 也是 SimpleVLA-RL 需要优化并行渲染的原因。

6.2.4 GRPO 目标函数: 把第 1 节的直觉写完整

SimpleVLA-RL 采用 GRPO 作为核心 RL 算法。第 1 节我们从” 同题采一组、平均分当基线” 建立了组相对优势的直觉, 这里把完整的优化目标写出来——SimpleVLA-RL 正是第一个真正要用到它的地方。

给定初始状态 s_0 , 行为策略 $\pi_{\theta_{\text{old}}}$ 生成 G 条轨迹 $\{\tau_i\}_{i=1}^G$, GRPO 的优化目标为:

$$J_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|\tau_i|} \sum_{t=1}^{|\tau_i|} \min \left(r_{i,t}(\theta) \hat{A}_i, \text{clip}(r_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_i \right) \right]$$

其中重要性采样比和归一化优势为:

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(a_{i,t}|s_{i,t})}{\pi_{\theta_{\text{old}}}(a_{i,t}|s_{i,t})}, \quad \hat{A}_i = \frac{R_i - \text{mean}(\{R_i\}_{i=1}^G)}{\text{std}(\{R_i\}_{i=1}^G)}$$

符号	含义
τ_i	同一初始状态下采出的第 i 条轨迹，其 token 数记作 $ \tau_i $
$r_{i,t}(\theta)$	新旧策略在第 t 个 token 上的概率比值（上一讲 PPO 的同款 ratio）
R_i	第 i 条轨迹的总奖励（结果奖励下为 0 或 1）
$\hat{A}_i$	组内归一化优势，整条轨迹共享
ϵ	clip 裁剪范围

这正是上一讲 PPO 的 clip 目标，只是优势换成了组相对优势：不需要训练额外的价值网络，减少了内存消耗；通过组内比较计算优势，天然适合结果奖励（成功/失败）的场景。

6.3 SimpleVLA-RL 方法

6.3.1 总体框架





图 7: SimpleVLA-RL 框架总览：从交互式 VLA rollout 到 GRPO 策略更新的完整流程

SimpleVLA-RL 的训练流程遵循“采样 → 评估 → 更新”的在线 RL 范式：



SimpleVLA-RL 应用于 OpenVLA-OFT——一个基于 OpenVLA 的自回归 VLA 模型，使用 LLaMA2-7B 作为骨干，采用 action chunk 和并行解码设计。选择自回归 VLA 的原因正是第 2 节的题眼：它天

然输出 action token 的概率分布，与 PPO 类 RL 算法兼容——既能通过随机采样产生多样轨迹，又能直接计算策略梯度。

6.3.2 交互式 VLA Rollout

VLA 的 rollout 与 LLM 有本质区别。LLM 只需一次性自回归生成完整 token 序列；VLA 则需要每个时间步与环境交互，获取新的视觉观测和本体感知状态后，才能生成下一个 action chunk。

SimpleVLA-RL 的 rollout 流程：

1. 对每个输入（场景 + 任务指令），复制 G 份并行初始化 G 个仿真环境
2. 在每个时间步，VLA 模型基于当前状态 s_t ，通过温度采样生成 action chunk $(a_t, a_{t+1}, \dots, a_{t+k-1})$
3. 机器人在环境中执行动作，环境返回新状态 s_{t+k} 和完成标志
4. 已完成的轨迹被移除，继续采样直到所有轨迹终止或达到最大步数

为了加速采样，SimpleVLA-RL 扩展了 veRL 框架，支持**并行多环境渲染**——多个仿真环境同时运行，显著降低了 rollout 的时间成本。

6.3.3 结果奖励建模

与传统 RL 方法需要精心设计奖励函数不同，SimpleVLA-RL 采用极其简单的二值结果奖励：

$$R(a_{i,t} | s_{i,t}) = \begin{cases} 1, & \text{is_successful}[\text{traj}_i(a_i, s_i)] \\ 0, & \text{otherwise} \end{cases}$$

轨迹级奖励被均匀传播到每个 action token：成功轨迹中的所有 token 获得奖励 1，失败轨迹中的所有 token 获得奖励 0。

这种设计的优势：

优势	说明
可扩展	无需为每个任务设计特定的奖励函数
通用性强	适用于任何有成功/失败判定的环境
避免过程约束	不限制完成任务的具体方式，给予模型更大的探索空间

6.3.4 探索增强策略

探索是 VLA RL 的关键瓶颈。操作任务通常允许多种有效解法，但 VLA 模型倾向于收敛到 SFT 数据中的少数固定模式。SimpleVLA-RL 引入三项探索增强策略：

(1) **动态采样 (Dynamic Sampling)**。无价值函数的 RL 算法（如 GRPO）在组内所有轨迹获得相同奖励时会产生零梯度——优势估计变为零，训练停滞。动态采样通过过滤掉全成功或全失败的组来解决这个问题：

$$0 < |\{\text{traj}_i \mid \text{is_successful}[\text{traj}_i]\}| < G$$

只保留包含混合结果（既有成功又有失败）的组，确保非零优势估计和稳定的梯度流。

(2) **提高裁剪上界 (Clip Higher)**。PPO/GRPO 使用裁剪限制策略更新幅度以保证稳定性。但上界裁剪会限制低概率 token 的概率提升，从而约束探索。SimpleVLA-RL 将裁剪范围从 $[1 - 0.2, 1 + 0.2]$ 调整为 $[1 - 0.2, 1 + 0.28]$ ，放宽上界以鼓励探索新行为。

(3) **提高 Rollout 温度**。将采样温度从 1.0 提高到 1.6，使 VLA 模型在 rollout 阶段生成更多样化的轨迹。更高的温度增加了 action token 分布的熵，促进对不同动作策略的探索。




图 8: 三项探索增强策略的消融实验：动态采样、提高裁剪上界和提高 rollout 温度均带来显著提升

备注：这三招都是在“基座已经相当强”（SFT 成功率 91%）的前提下鼓励探索。第 8 节我们的基座只有四五成功率时，会看到同样的旋钮要往**相反**方向拧——温度要降、KL 要加回来。方法没有对错，对不对要看基座。

6.3.5 训练目标

综合以上设计，SimpleVLA-RL 的最终优化目标为：

$$\mathcal{J}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|a_i|} \sum_{t=1}^{|a_i|} \min \left(r_{i,t}(\theta) \hat{A}_i, \text{clip}(r_{i,t}(\theta), 1 - \varepsilon_{low}, 1 + \varepsilon_{high}) \hat{A}_i \right) \right]$$

$$\text{s.t. } 0 < |\{\text{traj}_i \mid \text{is_successful}[\text{traj}_i]\}| < G$$

与标准 GRPO 相比, SimpleVLA-RL 做了两个关键修改:

修改	原因
移除 KL 散度正则化	消除对参考模型的依赖, 减少内存消耗并加速训练; 同时避免 KL 惩罚限制策略偏离参考模型, 从而约束探索
非对称裁剪	放宽上界 ($\varepsilon_{high} = 0.28$) 鼓励探索, 保持下界 ($\varepsilon_{low} = 0.2$) 确保稳定性 $\varepsilon_{low} \neq \varepsilon_{high}$

6.4 实验结果与讨论

SimpleVLA-RL 的实验部分不需要记住每个任务的完整表格, 更重要的是理解结果说明了什么。论文的评估覆盖三个层面: LIBERO 的语言引导操作任务、RoboTwin 1.0/2.0 的双臂仿真任务, 以及纯仿真训练后的真实世界迁移。所有核心实验都采用同一个思路: 先用 SFT 得到 OpenVLA-OFT 基线, 再在仿真环境中用 SimpleVLA-RL 继续训练。

6.4.1 主要结果: RL 把 SFT 的上限继续往上推

核心结果可以压缩成一张表:

评估场景	SFT 基线	+ SimpleVLA-RL	结果含义
LIBERO	91.0	99.1	在强 SFT 基线上持续提升, 超过 π_0 和 UniVLA 等已有 VLA 模型
RoboTwin 1.0	39.8	70.4	双臂操作任务平均提升 30.6 个百分点, 说明结果奖励能修正复杂控制策略
RoboTwin 2.0	38.3	68.8	在更复杂的域随机化任务中仍有 30.5 个百分点提升, 并超过 π_0 和 RDT
真实世界	17.5	38.5	只在仿真中 RL 训练, 也能带来真实世界平均成功率提升

这个结果的关键不是”RL 又涨了几个点”, 而是 **SFT 的高成功率并不等于策略已经学到了最优行为**。在 LIBERO 上, OpenVLA-OFT 的 SFT 基线已经达到 91.0%, 看起来相当强; 但 RL 仍能把平均成功率推到 99.1%, 其中 LIBERO-Long 从 86.5% 提升到 98.5%。这说明 SFT 主要学习的是”像示教一样做”, 而 RL 优化的是”能不能完成任务”。当评价标准从模仿轨迹转向任务成功, 模型还有继续改进的空间。

RoboTwin 2.0 的结果更能说明问题。短时任务、中时任务、长时和超长时任务全部提升, 整体从 38.3% 到 68.8%。这表明 SimpleVLA-RL 并不是只修补短动作误差, 而是在多步闭环任务里改善了动作序列的整体质量。长时程任务对局部错误非常敏感, 早期一个小偏差可能在后面被放大; RL 通过真实环境反馈训练, 正好能让模型学习如何从中间状态继续纠偏。

6.4.2 数据效率：RL 可以弥补示教数据不足

SimpleVLA-RL 最有价值的实验之一，是极端少数据设置。每个 LIBERO 任务只给 1 条示教轨迹时，SFT 平均成功率只有 48.9%，LIBERO-Long 只有 17.3%；但继续做 RL 后，平均成功率达到 96.9%。

设置	Spatial	Object	Goal	Long	平均
单轨迹 SFT	63.6	54.9	59.6	17.3	48.9
单轨迹 SFT + RL	98.2	98.7	98.8	91.7	96.9
提升	+34.6	+43.8	+39.2	+74.4	+48.0
全轨迹 SFT (每套 500 条)	91.6	95.3	90.6	86.5	91.0
全轨迹 SFT + RL	99.4	99.1	99.2	98.5	99.1
提升	+7.8	+3.8	+8.6	+12.0	+8.1

这里的”全轨迹”指每个 LIBERO 任务套件共 500 条示教轨迹，也就是 10 个任务、每个任务 50 条。对比最有冲击力的地方在于：**单轨迹 SFT + RL (96.9%) 甚至超过了全轨迹 SFT (91.0%)**。这不是说示教数据不重要，而是说示教数据的作用更像是给模型一个可探索的起点；一旦模型偶尔能成功，在线 RL 就可以通过成功/失败反馈继续放大有效行为。

这对 VLA 训练很关键。机器人示教轨迹昂贵、慢、难扩展，而仿真交互可以并行采样。SimpleVLA-RL 的结果说明：如果环境能提供可靠的成功判定，那么一部分”数据扩展”可以从人工示教转移到环境试错上。

6.4.3 泛化：RL 不只是记住训练任务

SimpleVLA-RL 在三个维度上评估了泛化能力：空间泛化 (LIBERO-Spatial)、物体泛化 (LIBERO-Object) 和任务泛化 (LIBERO-Goal)。

实验设置：每个任务套件的 10 个任务中，9 个用于训练，1 个保留为未见任务进行分布外评估。




图 9: 泛化分析示例 (Goal 套件未见任务): 随着已见任务成功率提升, RL 在未见任务上保持改善, 而 SFT 出现过拟合

核心发现：

- **SFT 严重过拟合**：随着训练任务成功率提升，SFT 在未见任务上的性能反而下降，甚至出现灾难性遗忘（成功率降至 0%）
- **RL 持续泛化**：随着训练任务成功率提升，SimpleVLA-RL 在未见任务上也持续改善，在所有三个维度上都优于 SFT
- **LIBERO-Goal 最具挑战性**：SFT 在训练开始时就立即在未见任务上降至 0%，因为 Goal 任务涉及多样化的物体和操作策略，跨任务可迁移的成分很少；而 RL 不仅避免了性能下降，还实现了 5%-15% 的提升

这组实验说明，SFT 的问题不只是”数据少”，还包括”优化目标太窄”。SFT 会把训练轨迹当作唯一正确答案，训练越久越可能贴合已见任务的具体分布；RL 则只关心结果是否成功，因此允许模型在不同初始状态、物体位置和任务表述下找到不同但有效的动作路径。这也是为什么 RL 在未见任务上更不容易崩掉。

6.4.4 Sim-to-Real: 仿真 RL 的收益能迁移到真实世界

模型	Stack Bowls	Place Cup	Pick Bottle	Click Bell	平均
RDT (SFT)	60.0	4.0	10.0	20.0	23.5
OpenVLA-OFT (SFT)	38.0	2.0	0.0	30.0	17.5
+ SimpleVLA-RL	70.0	10.0	14.0	60.0	38.5
提升	+32.0	+8.0	+14.0	+30.0	+21.0

整个训练过程**完全在仿真中完成**，不使用任何真实世界数据。SimpleVLA-RL 将真实世界平均成功率从 17.5% 提升到 38.5%，超过 RDT 的 23.5%。在 Stack Bowls 任务上实现了 96% 的相对提升（38% 到 70%）。

这个结果需要谨慎解读：38.5% 还不是一个可以直接部署的高成功率，但它证明了仿真 RL 学到的改进并没有完全被 sim-to-real gap 抹掉。换句话说，仿真不是只用来做离线数据生成，也可以成为策略继续优化的训练场。未来如果仿真质量、域随机化和真实世界安全探索结合得更好，这条路线有可能显著降低真实机器人试错成本。

6.4.5 行为变化：“Pushcut”说明 RL 在优化任务结果




图 10: Pushcut 现象：RL 训练后模型自主发现了推动策略（下），而非示教数据中的抓取-移动-放置策略（上）

SimpleVLA-RL 训练过程中观察到了一个引人注目的涌现现象——“**pushcut**”（push-driven shortcut，推动捷径）。在 RoboTwin 2.0 的 **move can pot** 任务中，所有示教轨迹都遵循“抓取 → 移动 → 放置”的标准策略。然而，RL 训练后，模型自主发现了一种更高效的解法：**直接推动罐子到目标位置**，绕过了抓取动作。类似现象也出现在 **place a2b left/right** 任务中。

“Pushcut”的意义在于，它非常直观地展示了 SFT 和 RL 的目标差异：

方法	行为模式
SFT	复制示教数据中的固定模式，无法超越数据分布
RL	通过奖励驱动的探索发现新策略；结果奖励不约束完成方式，给予模型更大的创新空间

这也是 SimpleVLA-RL 最值得讨论的地方。结果奖励不告诉模型“应该怎么做”，只告诉它“是否完成了任务”。因此，只要环境判定和真实任务目标一致，RL 就可能发现更短、更鲁棒、示教中不存在的策略。但这也带来一个反面提醒：如果奖励或成功判定设计得太粗糙，模型也可能学到投机行为。SimpleVLA-RL 能用二值结果奖励取得好效果，一个前提是这些操作任务的成功判定相对清晰。

6.4.6 失败边界：RL 需要最低初始能力

SimpleVLA-RL 并非万能。论文通过实验揭示了 RL 失效的条件：

SFT 数据量	SFT 成功率	+ RL 成功率	提升
0 条轨迹	0%	0%	0
100 条轨迹	7.3%	25.4%	+18.1
1000 条轨迹	28.2%	50.4%	+22.2

这张表正是第 5 节那条规律的实证。0 条 SFT 数据时，模型成功率为 0%，RL 也无法提升，因为它几乎采不到成功轨迹，优势估计没有正样本。100 条和 1000 条 SFT 数据都能带来提升，但初始能力越强，RL 越容易获得有效反馈。

因此，SimpleVLA-RL 更准确的定位是：**它不是替代 SFT，而是接在 SFT 后面，把”会模仿”进一步变成”会完成任务”**。SFT 负责提供基本动作先验和非零成功率，RL 负责在环境反馈中筛选、放大和修正策略。

6.5 局限性与未来方向

当前局限：

- **依赖自回归 VLA**：当前框架仅适用于输出 action token 概率分布的自回归 VLA（如 OpenVLA-OFT），不直接兼容 diffusion-based VLA（如 π_0 ）或回归式 VLA
- **需要最低初始能力**：RL 在基础模型完全无能力时失效，仍需一定量的 SFT 数据作为起点
- **仅使用结果奖励**：二值奖励在初始成功率极低时信号稀疏，可能需要引入过程奖励来引导早期探索
- **仿真依赖**：在线 RL 需要大量环境交互，目前依赖仿真器，真实世界在线 RL 的成本仍然很高
- **单视角输入**：为了训练和推理效率，SimpleVLA-RL 仅使用单视角图像，去掉了腕部相机，可能限制了某些精细操作任务的性能

未来方向：

- **扩展到更多 VLA 架构**：将 RL 框架适配到 diffusion-based 和 flow matching-based VLA 模型（第 9 节的 $\pi_{0.6}^*$ 正是朝这个方向迈出的的一大步）
- **引入过程奖励**：结合结果奖励和过程奖励（如距离目标的进展），改善低初始能力场景下的学习效率
- **真实世界在线 RL**：探索安全、高效的真实世界在线 RL 方法，减少对仿真器的依赖
- **更大规模的 RL 训练**：探索 RL 训练的 scaling law——更多环境、更多采样、更长训练是否能持续带来提升

6.6 本节小结

SimpleVLA-RL 的核心价值可以概括为五点：

1. **在线 RL 可以继续扩展 VLA 性能**：即使 SFT 已经很强，结果奖励仍能带来明显提升。
2. **数据效率显著提高**：单轨迹 SFT + RL 接近全轨迹 SFT + RL，说明示教数据不再是唯一扩展路径。
3. **泛化比 SFT 更稳**：RL 不强迫模型贴合固定示教轨迹，因此在未见任务上更不容易过拟合。
4. **仿真训练有真实迁移价值**：纯仿真 RL 能提升真实世界成功率，但距离可靠部署仍有差距。

5. **RL 的收益依赖初始能力**：模型必须先有偶尔成功的能力，否则二值结果奖励太稀疏，无法启动学习。

局限也同样清楚：只适用于自回归动作头、离不开仿真器、在基座太弱时无法启动。不过对本讲来说，它最重要的角色是”把路走通的人”——证明了数数实验的那套 GRPO 外壳搬到 VLA 上真的能涨点。下一个问题随之而来：这样的训练要用一整个 GPU 集群跑仿真、推理、训练三种负载，资源怎么编排才不浪费？这就是下一节 RLinf 的主题。

7 RLinf: VLA 强化学习的基建化

论文: *RLinf-VLA: A Unified and Efficient Framework for Reinforcement Learning of Vision-Language-Action Models*, Tsinghua University 等, 2025 (arXiv: 2510.06710)

7.1 为什么需要基建

回看 SimpleVLA-RL 的训练回路，一次迭代里其实混着三种完全不同的计算负载：

负载	干什么	资源特征
仿真	物理引擎步进 + 渲染观测图像	有的仿真器吃 CPU (如 LIBERO), 有的吃 GPU (如 ManiSkill)
生成	策略大批量自回归采样动作	GPU 推理, 吞吐敏感
训练	反向传播更新策略	GPU 训练, 显存敏感

三者彼此串行依赖：仿真等生成给动作，生成等仿真给观测，训练等两者凑够一批数据。若简单地顺序执行，GPU 会花大量时间空转等待——尤其是等 CPU 仿真。SimpleVLA-RL 借用 veRL 并扩展并行渲染，已经是在系统层面找补；RLinf-VLA 则把”资源编排”当成正题来解，目标是给 VLA 强化学习修一条谁都能跑的高速路。

7.2 一套接口，三种编排




图 11: RLinf-VLA 总览：统一接口对接多种仿真器、多种 VLA 模型与 PPO/GRPO 算法；提供共置、分置、混合三种 GPU 分配模式，训练吞吐最高提升 2.27 倍；单一统一模型在 LIBERO、ManiSkill、RoboTwin 上均取得高成功率

上图分三层读。顶层是**统一抽象**：仿真器（LIBERO、ManiSkill、RoboTwin）、VLA 模型（OpenVLA、OpenVLA-OFT）、RL 算法（PPO、GRPO）三个维度各自可插拔——换一个仿真器或换一个模型，不用重写训练系统。中层是本文的核心贡献，三种 **GPU 分配模式**：

- **共置 (collocated)**：仿真、生成、训练全部共享同一批 GPU，轮流使用。实现最简单，但同一时刻只有一种负载在跑；
- **分置 (disaggregated)**：三种负载各占一批 GPU、流水线衔接。各负载互不干扰，但流水线有气泡，分给仿真的卡在等待时照样闲着；
- **混合 (hybrid, 新提出)**：细粒度流水线——把 rollout 切成小段，仿真、生成在不同 GPU 组上交叠执行，气泡被压到最小。

混合模式把训练吞吐比基线提高最多 **2.27 倍**，整体训练提速 1.61 到 1.88 倍。底层的性能面板则给出算法侧的结果：同一套系统训练出的**单一统一模型**，在 130 个 LIBERO 任务上取得 98.11% 成功率、25 个 ManiSkill 任务上 97.66%，六个 RoboTwin 任务平均 86.63%、相对 SFT 基线大幅提升；各基准上的后训练增益大致在 20% 到 85% 之间。

7.3 对本讲的启示

RLinf 值得放进本讲，不在于又刷高了几个点，而在于它标志着一个阶段转换：**VLA 强化学习正在从“单篇论文附带的训练脚本”走向“可复用的公共基础设施”**——就像当年深度学习从手写反向传播走向框架。对使用者，复现门槛在下降；对研究者，比较不同算法终于有了同一条起跑线。

同时它反过来印证了第 2 节的题眼：基建做得再庞大，中间那层“RL 算法”始终只有薄薄一页纸——PPO、GRPO，插在仿真器和模型之间。系统复杂化的是**资源编排**，不是**学习原理**。这给了我们十足的底气：下一节就把这页纸从集群里抽出来，在单卡上手写一个最小可用版。

7.4 本节小结

RLinf-VLA 用统一接口把仿真器、VLA 模型、RL 算法三个维度解耦，用共置/分置/混合三种 GPU 编排把训练吞吐提高到最多 2.27 倍，并以单一模型在三大仿真基准上验证了大规模 VLA 强化学习的有效性。它的存在说明这条技术路线已经开始沉淀为基础设施；而算法内核依然轻薄，正适合我们亲手复刻。

8 实验：让 VLA-0 自我提升成功率

8.1 动手之前：先量提升空间

按第 5.4 节的规矩，动手前先量基线。不巧的是，官方训练充分的 VLA-0 在 LIBERO 上平均成功率已经刷到 94% 以上——接近饱和。对这样的基座做 GRPO，组内几乎全是成功轨迹，既没有学习信号，也没有提升空间。

课堂的解法是**自造一个弱基座**：用 VLA-0 的 0.5B 版本（SmolVLM2 骨干）在 LIBERO 的物体抓放套件上做**少步 SFT**，故意停在一个欠训练的 checkpoint 上，使它在目标任务上的成功率停在四到五成。这正是 5.4 节说的“最舒服的起点”：每组轨迹里既有成功也有失败，组内比较每次都有话可说。

备注：真实工程里你多半会拿到一个“已经很强”的基座，此时该做的不是硬做 RL，而是去找它还不行的更难任务（SimpleVLA-RL 的高价值场景全都是低成功率起点）。课堂上反其道自造弱基座，为的是让“后训练前后”的对比一眼可见。

8.2 训练循环：把数数的外壳搬过来

相对第 4 节的数数实验，这里的训练循环只换了两样东西——**策略的 token 含义和判分的方式**。整个循环如下：

1. 从任务的初始状态池里选一个初始状态，把 $G = 8$ 个并行仿真环境重置到同一初始状态——机器人版的“同一道题”；

2. 当前策略以温度 1.0 采样：每个环境里，VLA-0 把当前观测读进去，打印出一串整数、解码成动作执行，一步步走到任务成功或超时，得到 8 条轨迹；
3. 仿真器逐条判定成败，给出 0/1 奖励；
4. 组内标准化算出每条轨迹的相对优势（第 1.4 节的公式）；
5. 重放每条轨迹的 token 序列，在当前策略下重新计算每个动作 token 的 log 概率，按 GRPO 目标更新——外加一项对参考模型（冻结的 SFT 起点）的逐 token KL 惩罚。

和数数实验逐项对照：

环节	VLM 数数（第 4 节）	VLA-0（本节）
一道题	一张图 + 一个问题	一个初始状态 + 一条任务指令
一次作答	生成一段回答	rollout 一条轨迹（逐步与环境交互）
判分	比对答案字符串	仿真器判定任务成败
log 概率	文本 token	动作 token（数学上同构）
更新	GRPO	GRPO + KL

第 2 节的题眼在数学上完全兑现：优势计算、概率比值、梯度回传，一行都不用改。工程上多出来的是与仿真器的交互——rollout 比纯文本生成慢几个量级，CPU 仿真是瓶颈、GPU 大部分时间在等待。第 7 节集群要解的资源编排问题，在单卡上以”等”的形式亲身体会了一遍。完整的可运行训练代码将随课程代码一并发布。

外壳虽然照搬，路却不是一次走通的。接下来三小节是这次训练结结实实踩过的三道坎——每一道都对应稀疏奖励 RL 后训练的一条通用规律。

8.3 第一道坎：组里没有信号

现象：起初照搬”提高采样温度鼓励探索”的思路（第 6.3.4 节 SimpleVLA-RL 的第三招），把温度设到明显高于 1，结果训练几乎纹丝不动。

原因：温度是把双刃剑。对成功率 91% 的强基座，升温能让千篇一律的成功轨迹里冒出新解法；但对四五成功率的弱基座，升温后的随机扰动直接把有效成功率压到一成上下——8 条一组，接近半数的迭代整组全败，组内标准差为零、优势全零、**零梯度**。这正是动态采样要过滤的病态组，只不过在弱基座下病态组成了多数，过滤完也剩不下什么。

修法：把温度收回 1.0，即策略自己的自然分布。此时绝大多数（约 97%）的组是有成有败的混合组，每次迭代都有梯度可用。

这道坎留下的规律：**探索旋钮的方向由基座强弱决定**——强基座升温买多样性，弱基座守住温度保信号密度。同一个旋钮，两篇工作拧向相反，两边都是对的。

8.4 第二道坎：学了这个忘那个

现象：信号密了，训练动了，新问题浮出水面——每次迭代只在一个初始状态上更新时，策略在这个状态上稳步进步，其他初始状态的成功率却断崖式下跌，甚至从五成直接归零。

原因：大模型对窄分布的连续梯度极其敏感。连着多步只看同一个初始状态，等于在这个状态上过拟合，把别的状态上辛苦学来的能力“挤”掉了——顾此失彼。

修法：把每次迭代的更新摊到多个初始状态上，而且专挑那些基座成功率既不为零也不为一的初始状态：全败的死状态采了也是白采（8.3 的教训），全成的状态没东西可学（5.4 的天花板）。把采样预算全部花在“有信号”的状态上，既不遗忘、每步又都有效。

这与 6.3.4 的动态采样是同一个思想的两面：动态采样在采完之后过滤掉病态组，我们在采样之前就把预算押在有信号的状态上——单卡采样太贵，浪费不起。

8.5 第三道坎：越训越差

现象：前两道坎迈过，训练有梯度、状态不遗忘，可确定性评测给出了最反直觉的结果——成功率不升反降，几次迭代后从四五成掉到一成多。

原因：稀疏 0/1 奖励的信用分配是糊的。一条失败轨迹里其实有大量正确的动作（比如前半段完美接近了物体），整条被判负优势，好动作跟着挨罚；一条成功轨迹里也夹着无关甚至错误的动作，整条加分，坏习惯跟着受赏。没有任何约束时，这种带噪声的更新会把策略从 SFT 辛苦到达的胜任区一步步拖走。注意这不同于 8.4 的遗忘——那是状态之间的顾此失彼，这是整体能力的漂移退化。

修法：把第 1.5 节介绍的 KL 锚加回来——对冻结的参考模型（SFT 起点）逐 token 施加 KL 惩罚。它像一根锚链：策略梯度仍然可以在链长范围内向高奖励方向探索，但再也无法漂离胜任区。

这一修的效果有一组干净的消融作证：同样的配置、同样的训练步数，唯一的区别是有没有 KL——无 KL 的策略掉到 16.7%，有 KL 的升到 66.7%。一个变量，天壤之别。

对照第 6 节又是一处“方向相反、两边都对”：SimpleVLA-RL 特意移除 KL（6.3.5 的表），因为强基座加 clip 已经够稳，去掉 KL 省显存、放开探索；弱基座上我们实测必须加回来。学习率同理——过大的学习率同样会把策略推出胜任区，这里用小学习率与 KL 配合。

8.6 结果：涨点、对照与早停

把整条训练线的关键数字放在一张图里：




图 12: VLA-0 后训练成功率对照：弱基座 50%，无 KL 的 GRPO 退化到 16.7%，加 KL 锚定后提升到 66.7%（LIBERO 物体抓放任务，贪婪解码评测）

配置	任务成功率（贪婪评测）
弱基座（少步 SFT）	40% ~ 50%（两轮评测，n=10 / n=20）
GRPO 无 KL，两次迭代后	16.7%
GRPO + KL，两次迭代后	66.7% （n=12） / 60%（n=20）
GRPO + KL，四次迭代后	16.7%

这张表要读出三件事：

1. **涨点成立**。同一套 GRPO 外壳作用在动作 token 上，把弱基座从 40% ~ 50% 推到 60% ~ 67%——第 2 节的题眼从推论变成了实测；
2. **KL 是关键变量**。中间两行的消融再次强调：稀疏奖励下没有锚，纯组相对策略梯度会亲手毁掉基座；
3. **峰值之后会退化**。最后一行是最诚实的一行：继续训到四次迭代，成功率又掉回 16.7%。KL 延缓漂移但不根治，稀疏奖励 VLA 后训练的典型形态就是”**早峰值、后退化**”——必须边训边评，在峰值处**早停**、取走峰值 checkpoint。这不是实现粗糙，而是该方向公认的不稳定性；SimpleVLA-RL 用强基座和大规模采样缓解了它，但同样要挑 checkpoint。

备注：判断”学没学到”必须看**贪婪解码**的确定性评测。训练过程中的采样成功率带着温度，天然偏低（这里只有两三成），那是探索的代价，不是策略的真实水平——只盯训练曲线会严重低估模型。

最后看一眼画面。下图取同一个初始状态：上排是弱基座，机械臂在物体上方反复试探、始终没能完成

抓取，回合以失败告终；下排是后训练模型，同样的起点，果断抓起目标物体放进篮子。




图 13: 同一初始状态的后训练前后对照：上排为弱基座 rollout，抓取失败；下排为 GRPO 加 KL 后训练模型，成功完成抓放任务

8.7 本节小结

把 token 从文字换成动作、判分从比答案换成仿真判定，同一套 GRPO 外壳在单卡可及的规模上给 VLA-0 带来了 40%~50% 到 60%~67% 的真实涨点。三道坎各留一条规律：采样温度的方向要看基座强弱；更新要摊到多个有信号的初始状态；稀疏奖励必须 KL 锚定，且峰值后退化不可避免、要靠早停收获成果。局限同样明确：单任务、离不开仿真器的判定与重置。它们指向同一个问题——真实世界里既没有自动判分、也没有一键重置，VLA 的后训练还能做吗？下一节的 $\pi_{0.6}^*$ 给出了目前最有分量的回答。

9 $\pi_{0.6}^*$: 让 VLA 从真实经验中学习

论文: $\pi_{0.6}^*$: a VLA That Learns From Experience, Physical Intelligence, 2025 (arXiv: 2511.14759)




图 14: RECAP 总览: 从预训练 VLA 出发, 通过 advantage conditioning 让模型从真实世界经验中学习。系统部署模型并收集自主 rollout 和在线人类纠正, 然后微调价值函数以改进 advantage 估计, 再用更新后的 advantage 条件化训练 VLA 策略

9.1 背景与动机

9.1.1 从模仿学习到经验学习

第 11、12 讲里我们认识了 π_0 和 $\pi_{0.5}$; $\pi_{0.6}$ 是这条线的最新一代, 换上了更大的 Gemma 3 骨干和更强的 action expert, 但训练范式没变, 仍是监督微调 (SFT) / 行为克隆 (BC): 给模型看专家演示, 让它模仿每一步动作。

而模仿学习有一个根本性问题: **模型最多只能和演示数据一样好**。更关键的是, 一旦执行时偏离了专家轨迹, 模型就进入了训练数据没有覆盖的状态, 误差会不断累积。

人类学习技能的方式不是这样的。人类在学会基本动作后, 会通过**反复练习**来精进——从失败中学习, 从纠正中改进, 逐渐超越最初的教学水平。 $\pi_{0.6}^*$ 和 RECAP 方法正是要把这种“从经验中学习”的能力赋予 VLA 模型。

9.1.2 VLA 强化学习的挑战

第 14 讲和本讲前几节已经建立了 RL 后训练 VLA 的基本思路, 也亲手跑通了 GRPO 版本。但把 RL 真正应用到最大规模的 VLA 模型和真实世界部署上, 还面临几个特殊挑战:

挑战	具体表现
模型规模	$\pi_{0.6}$ 使用 Gemma 3 4B 骨干 + 860M 参数的 action expert，直接用 PPO 等在线策略梯度方法训练成本极高
动作表示	$\pi_{0.6}$ 使用 flow matching 生成连续动作，不像离散 token 那样有现成的 log-likelihood，传统策略梯度方法难以直接应用
数据异构	真实部署中的数据来源多样：专家演示、自主 rollout、人类纠正干预，需要一个统一框架处理
真实世界部署	不是仿真环境，每次数据收集都有成本，需要高效利用所有数据

第二行正是第 2 节题眼划出的边界：flow matching 动作头没有干净的 log 概率，GRPO 那套外壳套不上去。 $\pi_{0.6}^*$ 走的就是那条“绕行的路”。

9.1.3 RECAP 的核心思路

RECAP (RL with Experience and Corrections via Advantage-conditioned Policies) 提出了一个不同于 PPO/GRPO 的 RL 方案：**advantage conditioning**。

核心思想可以用一句话概括：

不用策略梯度更新模型，而是把“这个动作好不好”作为一个额外输入条件，让模型学会区分好动作和坏动作，推理时只要求模型输出“好动作”。

这个方法有几个关键优势：

1. **兼容 flow matching**：不需要计算 log-likelihood，只需要在输入中加一个条件标记
2. **能利用所有数据**：好数据和坏数据都有用——好数据标记为 positive，坏数据标记为 negative
3. **训练稳定**：本质上还是监督学习，只是多了一个条件输入，不需要复杂的策略梯度估计
4. **可迭代改进**：收集新数据 → 更新价值函数 → 重新计算 advantage → 重新训练策略

9.2 从正则化强化学习到 Advantage Conditioning

9.2.1 问题设定

RECAP 使用标准的 RL 框架。策略 $\pi(\mathbf{a}_t|\mathbf{o}_t)$ 根据观测 $\mathbf{o}_t$ 选择动作 $\mathbf{a}_t$ 。一条轨迹定义为：

$$\tau = (\mathbf{o}_0, \mathbf{a}_0, \mathbf{o}_1, \mathbf{a}_1, \dots, \mathbf{o}_T)$$

这里 τ 表示一条完整 episode； $\mathbf{o}_t$ 是第 t 个时刻的观测，通常包含多路相机图像、机器人关节状态和任务语言； $\mathbf{a}_t$ 是策略在该观测下输出的机器人动作； T 是 episode 结束时刻。论文为了简洁，把观测近似看作 Markov 状态，也就是默认当前观测已经足够判断下一步该怎么做。

RL 的目标是最大化累计奖励（回报）：

$$\mathcal{J}(\pi) = \mathbb{E}_{\tau \sim \rho_\pi} \left[\sum_{t=0}^T r_t \right]$$

其中 ρ_π 是策略 π 和真实环境动力学共同诱导出的轨迹分布， $r_t = r(\mathbf{o}_t, \mathbf{a}_t)$ 是即时奖励。这个式子的意思是：如果反复让策略 π 执行任务，它会产生很多条轨迹， $\mathcal{J}(\pi)$ 就是这些轨迹总奖励的平均值。RECAP 中没有使用折扣因子；如果写成带折扣的形式，可以把 γ 取为 1。

价值函数和优势函数的定义与第 14 讲一致：

$$V^\pi(\mathbf{o}_t) = \mathbb{E} \left[\sum_{t'=t}^T r_{t'} \right], \quad A^\pi(\mathbf{o}_t, \mathbf{a}_t) = \mathbb{E} \left[\sum_{t'=t}^{t+N-1} r_{t'} + V^\pi(\mathbf{o}_{t+N}) \right] - V^\pi(\mathbf{o}_t)$$

这里 $V^\pi(\mathbf{o}_t)$ 是“从当前观测继续执行策略 π ，预期还能拿到多少回报”； $A^\pi(\mathbf{o}_t, \mathbf{a}_t)$ 是动作 $\mathbf{a}_t$ 相对策略平均行为的优势； N 是 n-step 估计的前瞻步数。优势函数可以理解为一个局部比较：先真实执行当前动作并看未来 N 步，再加上第 $t+N$ 步的价值估计，最后减掉原状态价值。如果 $A > 0$ ，说明这个动作比当前策略在该状态下的平均选择更好；如果 $A < 0$ ，说明它拖慢了进度或更容易导致失败。

是的，你没看错——**价值函数在这里回来了**。第 1 节 GRPO 靠“同题采一组”把 critic 请走，靠的是仿真里可以随意重复初始状态；真实世界没有这个奢侈条件，每条轨迹的初始状态都独一无二，组内比较无从谈起，“平均水平”的参照只能重新请价值函数来估。请走与请回，都是同一笔账在不同场景下的最优解。

9.2.2 正则化强化学习

RECAP 的理论基础来自**正则化 RL**。与直接最大化回报不同，正则化 RL 在优化奖励的同时，要求新策略不要偏离参考策略 π_{ref} 太远：

$$\mathcal{J}(\pi, \pi_{\text{ref}}) = \mathbb{E}_{\tau \sim \rho_\pi} \left[\sum_{t=0}^T \gamma^t r_t \right] - \beta \mathbb{E}_{\mathbf{o} \sim \rho_\pi} [D_{\text{KL}}(\pi(\cdot|\mathbf{o}) \| \pi_{\text{ref}}(\cdot|\mathbf{o}))]$$

这里 π_{ref} 是参考策略，通常可以理解为收集数据的行为策略或上一阶段策略； D_{KL} 衡量新策略和参考策略在同一观测下的动作分布差异； β 是正则强度； γ 是折扣因子。论文在基础 RL 设定中不使用折扣，所以上一节等价于 $\gamma = 1$ ；这里保留 γ 是为了呈现正则化 RL 的通用写法。

这个“别偏离参考策略太远”的思想我们已经见过两次了：第 1.5 节 GRPO 的 KL 项、第 8.5 节救回训练的那根锚链，都是它。当 D 取 KL 散度时，这个优化问题有一个经典的闭式解（推导用拉格朗日乘子法 + 对 π 求泛函导数即可，AWR、MPO 等论文都给过；这里直接借用结果）：

$$\hat{\pi}(\mathbf{a}|\mathbf{o}) \propto \pi_{\text{ref}}(\mathbf{a}|\mathbf{o}) \exp(A^{\pi_{\text{ref}}}(\mathbf{o}, \mathbf{a})/\beta)$$

这里 $\hat{\pi}$ 是理论上的改进策略； $\propto$ 表示右侧还要除一个归一化常数，让所有动作的概率加起来为 1。

读这个式子最简单的方法是把它拆成两步：**先看参考策略给每个动作的概率，再乘上一个” 奖罚因子” $\exp(A/\beta)$ 。**

- 如果某动作 $A > 0$ （比平均更好）， $\exp(A/\beta) > 1$ ，它在新策略里的概率被**放大**；
- 如果 $A < 0$ （比平均更差）， $\exp(A/\beta) < 1$ ，它的概率被**压缩**；
- $A = 0$ 的动作权重为 1，等于不动。

β 控制正则化强度：

- β 很小， $\exp(A/\beta)$ 对 advantage 极敏感，新策略只会把概率几乎全压在少数高 advantage 动作上，激进；
- β 很大，所有动作的权重都接近 1，新策略几乎等于 π_{ref} ，保守。

可以把 β 想成”我对 advantage 估计的信任程度”——估得准就敢取小，估得糙就要取大。

这个结果是 PPO、AWR、MPO 等很多 RL 算法的理论基础。RECAP 的 advantage conditioning 也从这里出发，但走了一条不同的路。

9.2.3 从闭式解到 Advantage Conditioning

上面的闭式解虽然优美，但直接用它来更新策略并不容易——尤其是当策略用 flow matching 表示时，我们甚至无法高效计算 $\pi_{\text{ref}}(\mathbf{a}|\mathbf{o})$ 。

RECAP 的核心技巧是**把 advantage 翻译成**一个**虚拟事件的概率**。引入一个二元随机变量 $I \in \{0, 1\}$ ： $I = 1$ 代表”这是个改进动作”， $I = 0$ 代表”不是”。然后用 advantage 来定义这个事件发生的概率：

$$p(I|A^{\pi_{\text{ref}}}(\mathbf{o}, \mathbf{a})) = \frac{g(A^{\pi_{\text{ref}}}(\mathbf{o}, \mathbf{a}))}{\int g(A^{\pi_{\text{ref}}}(\mathbf{o}, \mathbf{a}')) d\mathbf{a}'}$$

读这个式子时只需要把握两点：

- g 是**任意单调递增函数**——advantage 越高，分子越大， $p(I|A)$ 越大。具体取什么 g 不重要（最自然的选择就是 $g = \exp$ ，刚好对应上一节的指数加权解），重要的是它把”动作好坏”映射成了一个 0 到 1 之间的权重；
- 分母里的 $\mathbf{a}'$ 是积分变量，作用就是凑一个归一化常数。 $p(I|A)$ 不需要有”真实的概率含义”，它只要是一个**形式上合法的概率**，方便我们紧接着用贝叶斯公式做变形。

把 $p(I|A)$ 当成上一节那个”奖罚因子”，原来的策略改进解就可以等价地重写成：

$$\hat{\pi}(\mathbf{a}|\mathbf{o}) \propto \pi_{\text{ref}}(\mathbf{a}|\mathbf{o}) p(I|A^{\pi_{\text{ref}}}(\mathbf{o}, \mathbf{a}))^\beta$$

CFGRL 论文证明这个策略**保证优于参考策略** ($\mathcal{J}(\hat{\pi}) \geq \mathcal{J}(\pi_{\text{ref}})$)。直觉与前面一致: π_{ref} 提供动作分布的”底座”, $p(I|A)^\beta$ 负责把”更像改进动作”的动作放大、其他压低。本质上换汤不换药——只是把 $\exp(A/\beta)$ 换成了 $p(I|A)^\beta$ 。

接下来用一次贝叶斯公式做关键的换形。考虑联合分布 $p(\mathbf{a}, I|\mathbf{o})$, 它描述的是: 在已经看到观测 $\mathbf{o}$ 的前提下, **同时采到动作 $\mathbf{a}$, 并且这个动作被标记为改进动作 I** 的概率。这个联合事件可以从两个角度展开:

1. **先采动作, 再判断好坏**: 先按照参考策略在观测 $\mathbf{o}$ 下采样动作 $\mathbf{a}$, 概率是 $\pi_{\text{ref}}(\mathbf{a}|\mathbf{o})$; 然后根据这个动作和观测判断它是否属于 I , 概率是 $p(I|\mathbf{a}, \mathbf{o})$ 。
2. **先限定好坏, 再看动作分布**: 先考虑在观测 $\mathbf{o}$ 下出现改进动作这个事件, 概率是 $p(I|\mathbf{o})$; 再看如果已经知道动作属于 I , 参考策略中这些动作的条件分布是什么, 也就是 $\pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o})$ 。

这两个角度描述的是同一个联合概率, 所以它们必须相等:

$$p(\mathbf{a}, I|\mathbf{o}) = p(I|\mathbf{a}, \mathbf{o}) \pi_{\text{ref}}(\mathbf{a}|\mathbf{o}) = \pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o}) p(I|\mathbf{o})$$

这个式子里的四项可以逐个理解:

- $\pi_{\text{ref}}(\mathbf{a}|\mathbf{o})$ 是**无条件动作分布**: 只看当前观测, 参考策略本来会多大概率输出动作 $\mathbf{a}$;
- $p(I|\mathbf{a}, \mathbf{o})$ 是**动作质量判断**: 给定这个动作和观测, 它有多大概率被认为是改进动作;
- $\pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o})$ 是**高质量动作子分布**: 在已经筛选出 I 这类动作后, 动作 $\mathbf{a}$ 在其中占多大比例;
- $p(I|\mathbf{o})$ 是**状态级基准概率**: 在当前观测下, 整体上有多大概率采到一个改进动作。它只和 $\mathbf{o}$ 有关, 不随具体动作 $\mathbf{a}$ 改变。

两式联立、把 $p(I|\mathbf{a}, \mathbf{o})$ 解出来:

$$p(I|\mathbf{a}, \mathbf{o}) = \underbrace{\frac{\pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o})}{\pi_{\text{ref}}(\mathbf{a}|\mathbf{o})}}_{\text{依赖}\mathbf{a}} \cdot \underbrace{p(I|\mathbf{o})}_{\text{不依赖}\mathbf{a}}$$

由于 advantage 是由 $(\mathbf{o}, \mathbf{a})$ 完全决定的, $p(I|A^{\pi_{\text{ref}}})$ 和 $p(I|\mathbf{a}, \mathbf{o})$ 在数值上是同一个东西。又因为右边第二项 $p(I|\mathbf{o})$ 不依赖 $\mathbf{a}$, 对 $\mathbf{a}$ 而言是常数, 会被 $\propto$ 关系里的归一化吸收掉, 所以可以丢掉它, 只保留:

$$p(I|A^{\pi_{\text{ref}}}(\mathbf{o}, \mathbf{a})) \propto \frac{\pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o})}{\pi_{\text{ref}}(\mathbf{a}|\mathbf{o})}$$

这一步是整个推导的关键: **它把”对 advantage 的指数加权”换成了”在 I 条件下的动作分布与无条件分布的比值”**。前者需要显式计算 advantage 再代到 exp 里, 后者是两个分布之比——后面会看到, 这正好让我们能用一个条件生成模型把”打分”内化进策略本身。

把它代回 $\hat{\pi}$ 的表达式 (顺便加上语言指令 ℓ , 因为 VLA 的所有分布都要条件在任务上):

$$\hat{\pi}(\mathbf{a}|\mathbf{o}, \ell) \propto \pi_{\text{ref}}(\mathbf{a}|\mathbf{o}, \ell) \left(\frac{\pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o}, \ell)}{\pi_{\text{ref}}(\mathbf{a}|\mathbf{o}, \ell)} \right)^\beta$$

加入 ℓ 是因为同一帧画面在不同任务下”好动作”完全不同：让机器人去拿杯子和让它擦桌子，对着同样的桌面应该输出截然不同的轨迹。

关键时刻：把 $\beta = 1$ 代进去。括号里的 β 次方消失，乘上前面的 $\pi_{\text{ref}}(\mathbf{a}|\mathbf{o}, \ell)$ 后，分子分母上的 $\pi_{\text{ref}}(\mathbf{a}|\mathbf{o}, \ell)$ 直接抵消：

$$\hat{\pi}(\mathbf{a}|\mathbf{o}, \ell) \propto \pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o}, \ell)$$

而 $\pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o}, \ell)$ 本身就是合法分布（对 $\mathbf{a}$ 积分等于 1），所以这里的归一化常数恰好是 1，可以把 $\propto$ 升级成等号：

$$\hat{\pi}(\mathbf{a}|\mathbf{o}, \ell) = \pi_{\text{ref}}(\mathbf{a}|I, \mathbf{o}, \ell)$$

这个式子读起来非常朴素：“改进后的策略”就等于“参考策略在 $I =$ 改进这个标签下的条件分布”。

把它翻译成工程语言，就是 advantage conditioning 的全部精髓：

如果我能训一个模型把”在 I 条件下从数据里采动作”学会，那推理时往这个模型输入 $I = \text{True}$ ，输出就直接是改进后的策略——不需要算 advantage、不需要算 log-likelihood、不需要策略梯度。

9.3 RECAP 方法详解

RECAP 的完整流程由三个步骤组成，可以迭代执行：

1. **数据收集：**部署 VLA 执行任务，标注成功/失败，可选地提供人类纠正干预
2. **价值函数训练：**用所有数据训练一个多任务分布式价值函数
3. **Advantage 条件化训练：**用价值函数计算 advantage，条件化训练 VLA 策略

9.3.1 分布式价值函数训练

为什么需要价值函数。 Advantage conditioning 需要知道每个动作的 advantage 值。而 advantage 的计算依赖价值函数 $V^\pi(\mathbf{o}_t)$ ——它估计从当前状态出发，未来能获得多少回报。

分布式价值函数。 RECAP 不是直接预测一个标量价值，而是训练一个**分布式价值函数** (distributional value function)：

$$p_\phi(V|\mathbf{o}_t, \ell) \in \Delta_B$$

这里 ϕ 是价值函数的参数, V 是要预测的未来回报, Δ_B 表示 B 维概率单纯形, 也就是长度为 B 、元素非负且总和为 1 的概率向量。换句话说, 模型不是直接输出”当前价值是 -0.37”这样的单个数, 而是输出”价值落在每个 bin 中的概率”。

它把价值空间离散化为 $B = 201$ 个 bin, 输出一个概率分布。训练目标是最小化交叉熵:

$$\min_{\phi} \mathbb{E}_{\tau \in \mathcal{D}} \left[\sum_{\mathbf{o}_t \in \tau} H(R_t^B(\tau), p_\phi(V|\mathbf{o}_t, \ell)) \right]$$

其中 $\mathcal{D}$ 是当前训练数据集, 包含演示、自主 rollout 和纠正数据; $R_t(\tau) = \sum_{t'=t}^T r_{t'}$ 是轨迹 τ 从时刻 t 开始的 Monte Carlo 实际回报 (一个标量); $R_t^B(\tau)$ 是把这个标量回报翻译成的**长度 B 的目标概率向量**——常见做法是 two-hot 编码: 找到 R_t 落在的两个相邻 bin, 按距离把概率分摊给它们, 使期望恰好等于 R_t ; $H(\cdot, \cdot)$ 是交叉熵。

这个目标的含义其实非常直白: 对数据集里每条轨迹的每个观测, 都让价值函数预测”从这里到 episode 结束最终会拿到多少回报”——只是它预测的不是一个数, 而是一张”回报落在哪个区间”的柱状图。

设计选择	说明
分布式而非标量	分布式价值函数能捕捉回报的不确定性, 训练更稳定
Monte Carlo 估计	直接用轨迹的实际回报作为目标, 不需要 bootstrapping, 简单可靠
多任务	同一个价值函数处理所有任务, 通过语言指令 ℓ 区分

从分布中提取连续价值:

$$V^{\pi_{\text{ref}}}(\mathbf{o}_t, \ell) = \sum_{b=0}^B p_\phi(V = b|\mathbf{o}_t, \ell) \cdot v(b)$$

其中 $v(b)$ 是第 b 个 bin 对应的连续价值。这个式子就是对离散价值分布求期望: 每个 bin 的价值乘以该 bin 的概率, 再全部加起来。

价值函数架构。价值函数使用与 VLA 相同的架构设计, 但骨干更小——670M 参数的 Gemma 3 VLM。它接收与 VLA 相同的输入 (图像、语言指令), 输出价值分布。为防止过拟合, 价值函数也会在少量多模态网络数据上联合训练。




图 15: 模型架构: VLA 使用预训练 VLM 骨干, 联合训练 next-token prediction 和 flow-matching action expert; 策略以二值化的 advantage 指示器为条件, 该指示器由独立的价值函数提供

奖励函数设计。 RECAP 使用一个通用的稀疏奖励定义, 适用于几乎所有任务:

$$r_t = \begin{cases} 0 & \text{if } t = T \text{ and success} \\ -C_{\text{fail}} & \text{if } t = T \text{ and failure} \\ -1 & \text{otherwise} \end{cases}$$

这里 T 是 episode 的最后一步, C_{fail} 是一个足够大的失败惩罚常数。直觉: 每多走一步就扣 1 分, 成功完成不额外扣分, 失败则在终点扣一个大的负分。这样价值函数学到的就是”距离成功还有多少步”的负数: 越接近成功, 剩余负奖励越少, 价值越接近 0; 如果最终失败, 价值会明显更低。

实际中, 价值被归一化到 $(-1, 0)$ 区间, 其中 0 表示成功完成, -1 表示最差情况。不同任务的最大 episode 长度不同, 所以按任务分别归一化。




图 16: 价值函数可视化：左侧是成功的叠衣服任务，右侧是失败的操作任务。红色部分表示价值下降（犯错），绿色部分表示价值上升（进展顺利）。价值函数能正确识别 episode 中的错误和进展速度

9.3.2 Advantage 条件化策略训练

改进指示器。有了价值函数，就可以计算每个动作的 advantage：

$$A^{\pi_{\text{ref}}}(\mathbf{o}_t, \mathbf{a}_t, \ell) = \sum_{t'=t}^{t+N-1} r_{t'} + V^{\pi_{\text{ref}}}(\mathbf{o}_{t+N}) - V^{\pi_{\text{ref}}}(\mathbf{o}_t)$$

其中 N 是前瞻步数（微调阶段使用 $N = 50$ ）。这条式子可以拆成”实际值 vs 默认值”的对比：

- $\sum_{t'=t}^{t+N-1} r_{t'} + V^{\pi_{\text{ref}}}(\mathbf{o}_{t+N})$ ——“**实际值**”：真的执行了数据里这条轨迹接下来的 N 步，然后用价值函数估计从第 $t + N$ 步开始还能拿到多少。这是”采用了这个动作之后真实发生的总回报估计”。
- $V^{\pi_{\text{ref}}}(\mathbf{o}_t)$ ——“**默认值**”：还没执行任何动作时，从当前观测出发的平均回报。这是”如果按 π_{ref} 平均水平办事，能拿到多少”。
- 两者相减 = 这个动作比”平均水平”多挣（或多亏）了多少。

所以 advantage 的符号意义非常清晰：让机器人更快接近成功或避免失败的动作，实际值高于默认值， A 偏正；造成卡顿、退步或增加失败风险的动作，实际值低于默认值， A 偏负。

然后将 advantage 二值化为改进指示器：

$$I_t = \mathbf{1}(A^{\pi_{\text{ref}}}(\mathbf{o}_t, \mathbf{a}_t, \ell) > \epsilon_\ell)$$

这里 $\mathbf{1}(\cdot)$ 是指示函数，条件成立时输出 1，否则输出 0； I_t 就是二值化后的 advantage 标签； ϵ_ℓ 是每个任务单独设置的阈值，控制多少数据被标记为”positive”。注意它不是固定的 0：论文发现通过阈值控制 positive 的比例，比在推理时用很大的 CFG 权重更稳定。

参数	预训练阶段	微调阶段
ϵ_ℓ	约 30% 的演示数据为 positive	通常约 40% 的 rollout 数据为 positive; 最难的叠衣服任务约 10%
N (前瞻步数)	用整条 episode 总回报减当前价值作高方差估计	$N = 50$

为什么要二值化而不是直接用连续 advantage? 因为二值化后, 条件输入就变成了一个简单的文本标记 (“Advantage: positive” 或 “Advantage: negative”), 可以直接嵌入到 VLA 的语言输入中, 不需要修改模型架构。预训练阶段论文使用整条 episode 回报减当前价值这样的估计, 主要是为了在大规模预训练中只做一次价值函数推理, 虽然方差更高, 但在海量多任务数据上效果足够好。

训练目标。策略的训练目标是同时学习无条件分布和条件分布:

$$\min_{\theta} \mathbb{E}_{\mathcal{D}_{\pi_{\text{ref}}}} [-\log \pi_{\theta}(\mathbf{a}_t | \mathbf{o}_t, \ell) - \alpha \log \pi_{\theta}(\mathbf{a}_t | I_t, \mathbf{o}_t, \ell)]$$

这里 θ 是 VLA 策略参数; $\mathcal{D}_{\pi_{\text{ref}}}$ 表示由参考行为策略产生的数据集, 在实际系统里它是人类演示、旧策略 rollout、新策略 rollout 和纠正片段的混合; $-\log \pi_{\theta}(\cdot)$ 是监督学习里的负对数似然损失。第一项让模型学习无条件的动作分布 (所有数据), 第二项让模型学习在给定改进标签 I_t 时的动作分布。 α 是权衡超参数: 越大, 模型越重视条件分布。

这个目标可以看成”一个模型, 两种问法”: 不提供 I_t 时, 它学数据整体的行为; 提供 $I_t = \text{positive}$ 时, 它学高 advantage 子集对应的行为。推理时使用 positive 条件, 相当于要求模型输出更像高质量片段的动作。

实际中, RECAP 使用 **advantage conditioning dropout**: 训练时 30% 的概率随机丢弃 I_t 条件。这替代了显式的 α 超参数, 同时使模型能在推理时使用 classifier-free guidance (CFG)。

与 $\pi_{0.6}$ 模型的结合。 $\pi_{0.6}$ 模型的输出包含三部分:

1. **子任务文本** $\hat{\ell}$: 自回归生成, 如”pick up the coffee cup”
2. **离散化动作** $a_{t:t+H}^\ell$: FAST tokenizer 编码的动作 token
3. **连续动作** $\mathbf{a}_{t:t+H}$: flow matching action expert 生成的动作 chunk

advantage 指示器 I_t 插入在子任务文本之后、动作之前, 因此只影响动作的生成。

对于连续动作部分, 精确的 log-likelihood 无法计算。RECAP 使用 flow matching 损失作为 log-likelihood 的下界:

$$\log \pi_{\theta}(\mathbf{a}_{t:t+H}, a_{t:t+H}^\ell | I_t, \mathbf{o}_t, \ell, \hat{\ell}) \geq \mathbb{E}_{\eta, \omega} \left[\log p_{\theta}(a_{t:t+H}^\ell | I_t, \mathbf{o}_t, \ell, \hat{\ell}) - \alpha_{\eta} \left\| \omega - \mathbf{a}_{t:t+H} - f_{\theta}(\mathbf{a}_{t:t+H}^{\eta, \omega}, I_t, \mathbf{o}_t, \ell, \hat{\ell}) \right\|^2 \right]$$

其中 H 是 action chunk 的长度, $a_{t:t+H}^\ell$ 是 FAST tokenizer 得到的离散动作 token, $\mathbf{a}_{t:t+H}$ 是连续动作 chunk, $\hat{\ell}$ 是模型先生成的子任务文本。 $\mathbf{a}_{t:t+H}^{\eta, \omega} = \eta \mathbf{a}_{t:t+H} + (1 - \eta) \omega$ 是加噪后的动作, $\omega \sim \mathcal{N}(0, \mathbf{I})$ 是

高斯噪声, $\eta \in [0, 1]$ 是 flow matching 的时间索引, f_θ 是 action expert 在该噪声水平上预测的速度场, α_η 是噪声相关的损失权重。

不要被符号吓住, 这个不等式想表达的事情其实很简单:

- **左边**是我们真正想最大化的”动作 log-likelihood”——但 flow matching 没法精确算它 (这是连续生成模型的通病);
- **右边**是它的一个下界, 可以拆成两块:
 1. **离散 token 的交叉熵** $\log p_\theta(a^\ell | \dots)$: 就是普通的语言模型负对数似然, 跟训 LLM 一样;
 2. **连续动作的 flow matching 均方误差** $\|\omega - \mathbf{a} - f_\theta(\dots)\|^2$: 就是 VLA 一直用的 flow matching 损失, 只不过把 I_t 也作为输入条件之一塞进去了。

换句话说, RECAP 没有为了 RL 强行改造 flow matching, 而是保留了原来稳定的监督式训练损失, 只是在输入里多塞一个 **advantage** 标签。这是它训练稳定的关键来源——拿来训普通 VLA 的那套代码, 几乎不改就能跑。

人类纠正的处理。在自主 rollout 过程中, 专家操作员可以介入提供纠正动作。对于这些纠正动作, RECAP 强制设置 $I_t = \text{True}$, 因为人类专家提供的纠正动作可以合理地假设为高质量动作。

整条 episode (包括自主部分和纠正部分) 都会被加入数据集, 无论是否发生了纠正。这种做法类似于 HG-Dagger (Human-Gated DAgger), 但 RECAP 额外利用了 RL 框架来处理自主数据。

9.3.3 推理时的策略改进: Classifier-Free Guidance

训练完成后, 默认使用 $\beta = 1$, 即直接从 $\pi_\theta(\mathbf{a} | I = \text{True}, \mathbf{o}, \ell)$ 采样。

但也可以通过 CFG 进一步锐化策略 ($\beta > 1$)。由于训练时使用了 advantage conditioning dropout, 模型同时学会了条件分布和无条件分布。在 flow matching 的框架下, 模型学到的实际上是 log-likelihood 的梯度, 因此可以按以下方式组合:

$$\nabla_{\mathbf{a}} \log \hat{\pi} = \nabla_{\mathbf{a}} \log \pi_\theta(\mathbf{a} | \mathbf{o}, \ell) + \beta (\nabla_{\mathbf{a}} \log \pi_\theta(\mathbf{a} | I, \mathbf{o}, \ell) - \nabla_{\mathbf{a}} \log \pi_\theta(\mathbf{a} | \mathbf{o}, \ell))$$

这个式子怎么来的? 其实就是把 9.2.3 节最终的策略改进解

$$\hat{\pi}(\mathbf{a} | \mathbf{o}, \ell) \propto \pi_{\text{ref}}(\mathbf{a} | \mathbf{o}, \ell) [\pi_{\text{ref}}(\mathbf{a} | I, \mathbf{o}, \ell) / \pi_{\text{ref}}(\mathbf{a} | \mathbf{o}, \ell)]^\beta$$

两边同时取 log, 再对 $\mathbf{a}$ 求梯度, 归一化常数对 $\mathbf{a}$ 求导后变成 0 自动消失, 整理后就是上面这个加权 score 形式。flow matching 推理时模型给出的本来就不是 $\log \pi$ 本身、而是它在动作空间里的梯度 (也就是 score $\nabla_{\mathbf{a}} \log \pi$), 所以推理时**直接在 score 层面做这个组合**就行, 不需要先把概率算出来。

可以分三步读这个式子:

- **基线方向** $\nabla_{\mathbf{a}} \log \pi_\theta(\mathbf{a} | \mathbf{o}, \ell)$: 告诉我们”无条件下, 往哪边动会让动作更像训练数据整体的样子”;

- **改进方向** 括号里的差: 是”加了 I 条件之后的 score 比无条件 score 多出来的部分”, 可以理解为”想要更像高 advantage 数据, 应该额外往哪边走”;
- **CFG 缩放 β** : 决定要把这个改进方向放大多少倍。 $\beta = 1$ 时整体退化为条件策略的 score; $\beta > 1$ 时会更激进地把动作推向 positive 条件偏好的区域。

实际中, 过高的 β 会把动作分布推向支撑集的边界 (导致过于激进的动作), 因此论文主要依赖训练时的阈值 ϵ_ℓ 来控制策略质量, 只在需要时使用适度的 CFG ($\beta \in [1.5, 2.5]$)。

9.3.4 完整算法流程

RECAP 的完整算法可以分为预训练和迭代改进两个阶段:

预训练阶段 (在大规模多任务多机器人数据集上):

1. 在所有演示数据 $\mathcal{D}_{\text{demo}}$ 上训练价值函数 V_{pre}
2. 用 V_{pre} 计算 advantage, 在 $\mathcal{D}_{\text{demo}}$ 上训练 advantage 条件化的 VLA π_{pre}

迭代改进阶段 (针对特定任务 ℓ):

3. 用任务演示数据初始化 $\mathcal{D}_\ell$, 从 V_{pre} 微调价值函数 V_ℓ^0
4. 从 π_{pre} 微调策略 π_ℓ^0 (此阶段固定 $I_t = \text{True}$, 等价于 SFT)
5. 对 $k = 1, 2, \dots, K$:
 - 用 π_ℓ^{k-1} 收集数据 (自主 rollout + 可选的人类纠正), 加入 $\mathcal{D}_\ell$
 - 从 V_{pre} 微调 V_ℓ^k (注意: 从预训练 checkpoint 微调, 不是从上一轮)
 - 从 π_{pre} 微调 π_ℓ^k (同样从预训练 checkpoint 微调)

每轮迭代都从预训练 checkpoint 开始微调, 而不是从上一轮的模型继续。这样做可以避免多轮迭代中的策略漂移——第 8.5 节我们靠 KL 锚链对抗的那种漂移, RECAP 用”每轮回到起点重训”从结构上杜绝了。

9.4 与其他策略提取方法的对比

9.4.1 为什么不用 PPO

上一讲介绍了 PPO, 本讲前几节的 GRPO 一族是当前 VLA 在线后训练的主流。但 RECAP 选择了 advantage conditioning 而非策略梯度, 原因有三:

1. **Flow matching 没有可计算的 log-likelihood**: PPO 需要计算 $\log \pi_\theta(\mathbf{a}|\mathbf{o})$ 来构造概率比值。但 $\pi_{0.6}$ 的连续动作由 flow matching 生成, 无法高效计算精确的 log-likelihood。虽然可以用近似方法, 但这引入了额外的近似误差。
2. **离线数据利用效率**: PPO 是 on-policy 方法, 每次更新都需要用当前策略采集新数据。在真实机器人上, 这意味着每次梯度更新都要等待机器人执行。RECAP 是 offline RL 方法, 可以在同一

批数据上反复训练。

3. **训练稳定性**: 论文实验中, PPO 需要非常小的信赖域约束才能在 off-policy 数据上稳定训练, 但也限制了策略改进的幅度。

9.4.2 为什么不用 AWR

AWR (Advantage Weighted Regression) 是另一种常见的 offline RL 方法, 它用 advantage 对数据进行加权: 高 advantage 的数据权重重大, 低 advantage 的数据权重小。

AWR 的问题是: 它会**丢弃或大幅降权大量数据**。低 advantage 的数据几乎不参与训练, 这本质上是一种过滤式模仿学习。而 RECAP 的 advantage conditioning 让模型从所有数据中学习——“好数据教模型” “什么是好动作”, “坏数据教模型” “什么是坏动作”。

9.4.3 实验对比

论文在最难的衣服任务上对比了 advantage conditioning、AWR 和 PPO。这里不需要记完整图表, 抓住结论即可:

1. **RECAP 的 advantage conditioning 最稳**: 它同时利用 positive 和 negative 数据, 既能提升成功率, 也不会明显牺牲执行速度, 因此吞吐量最高。
2. **AWR 的问题是动作变慢**: AWR 可以达到相对合理成功率, 但因为会过滤或降权大量低 advantage 数据, 学到的策略更保守, 吞吐量不如 RECAP。
3. **PPO 在这个设置下受限很大**: 为了在 off-policy 机器人数据上稳定训练, PPO 需要非常小的信赖域约束, 这让策略更新幅度过小, 最终改进有限。

所以这组对比的核心不是“换一个 RL 损失能不能涨点”, 而是说明: 对于 flow matching VLA 和真实机器人离线数据, 把 advantage 作为条件输入, 比直接做策略梯度或加权回归更适合工程落地。

9.5 实验结果

9.5.1 评估任务

论文在三类复杂的真实世界任务上评估 RECAP: 叠衣服、制作咖啡和组装箱子。它们共同覆盖了变形物体、液体操作、长时序多步骤任务和真实工厂部署场景。




图 17: 实验任务：包括三种叠衣服变体、组装箱子和制作咖啡饮品




图 18: 实验使用的双臂机器人平台：两个 6 自由度机械臂配备平行夹爪，50Hz 关节位置控制，三个相机（底座相机 + 两个腕部相机）

9.5.2 主要结果

实验结果可以概括为四个关键结论：

1. **RECAP 同时提升成功率和速度**：论文使用吞吐量（每小时成功完成任务数）作为核心指标，因为它同时反映任务是否成功和执行是否足够快。在多样叠衣服和咖啡任务上，加入真机数据后吞吐量超过 2 倍。
2. **SFT 高成功率不代表策略已经好用**：部分叠衣服任务在 SFT 后成功率已经接近上限，但 RECAP 仍然显著提升吞吐量。这说明 RL 学到的不只是”能不能完成”，还包括”能不能更快、更稳定地

完成”。

3. **最终策略达到可部署水平**: 除了最难的多叠衣服任务外, 最终模型在主要任务上的成功率都达到 90% 以上。论文展示了连续 13 小时制作咖啡、在新家中连续 2 小时叠衣服、在工厂中组装真实包装箱的演示。
4. **RECAP 可以针对性修复失败模式**: 在严格的 T 恤折叠标准下 (领口必须朝上居中), 两轮迭代后成功率达到 97%。这说明 RECAP 不只是整体提分, 也能用相对较少数据改变策略偏好, 消除特定错误。

9.6 RECAP 与本讲方法的关系

9.6.1 在课程体系中的位置

出处	方法	RL 类型	策略提取	适用场景
第 14 讲	PPO	在线 RL	策略梯度	从零训练控制策略
本讲第 6、8 节	SimpleVLA-RL / VLA-0 GRPO	在线 RL (GRPO)	组内相对优势	仿真环境中的自回归 VLA
本节	RECAP	迭代离线 RL	Advantage conditioning	大规模 VLA + 真实机器人

RECAP 与前面方法的关键区别:

1. **离线 vs 在线**: GRPO 一族需要在训练过程中持续与环境交互; RECAP 先收集一批数据, 再离线训练, 更适合真实机器人场景
2. **Advantage conditioning vs 策略梯度**: 不需要计算 log-likelihood, 天然兼容 flow matching
3. **规模**: RECAP 在数十亿参数的 VLA 上运行, 处理数万小时的多任务多机器人数据

9.6.2 与 Reward Conditioning 文献的关系

Advantage conditioning 的思想并非 RECAP 首创。它与以下工作有密切联系:

- **Decision Transformer**: 将 RL 问题转化为条件序列建模, 以 return-to-go 为条件
- **Upside-Down RL**: 用期望回报作为输入条件训练策略
- **CFGRL**: 将 classifier-free guidance 应用于 RL, 是 RECAP 最直接的理论基础

RECAP 的贡献在于: 将这些思想扩展到大规模 VLA 预训练和微调的完整流程中, 并在复杂的真实世界任务上验证了有效性。

9.7 本节小结

RECAP 和 $\pi_{0.6}^*$ 展示了一条将 RL 应用于大规模 VLA 的实用路径。核心要点：

- 1. **Advantage conditioning 是一种简洁的策略提取方法**：把”动作好不好”编码为输入条件，推理时只请求”好动作”。不需要策略梯度，不需要 log-likelihood，天然兼容 flow matching 等现代生成模型。
- 2. **分布式价值函数提供可靠的 advantage 估计**：用 Monte Carlo 回报训练，输出价值分布而非标量，多任务共享，训练简单稳定。
- 3. **异构数据统一处理**：演示数据、自主 rollout、人类纠正干预都可以纳入同一个框架——好数据标记为 positive，坏数据标记为 negative，纠正数据强制为 positive。
- 4. **迭代改进有效**：即使只做一轮数据收集和重训练，也能显著提升性能。在最难的任务上，吞吐量提升超过 2 倍，失败率降低约 2 倍。
- 5. **实际可部署**：最终模型在咖啡制作、叠衣服、箱子组装等任务上达到 90% 以上成功率，可以连续运行数小时。

站在整讲的视角，RECAP 还完成了一次意味深长的”请回”：第 1 节 GRPO 把价值函数请走，靠的是仿真里问题可以重复采样；到了真实世界，重复采样的奢侈没有了，价值函数又被请了回来——只不过换成了离线蒙特卡洛训练的分布式版本。同时它引入的人类纠正干预（操作员看着机器人跑、随时接管纠偏）已经把”人”放进了训练回路。**价值方法 + 人在环**，这两个火种正是下一讲的全部主题：HIL-SERL 会把它们做成一套在真机上一小时学会新任务的完整系统。

10 本讲小结

10.1 一套外壳，两个载体

本讲开头把 GRPO 从 PPO 里”减”了出来：**去 critic**——问题采一组、组内平均分当基线；**可验证奖励**——判分脚本替掉人工标注和奖励模型；**KL 锚定参考模型**——防止整场训练漂离胜任区。然后同一套外壳跑了两个载体：

	VLM 数数（第 4 节）	VLA-0 抓放（第 8 节）
策略 token	文本	动作（离散成整数的文本）
判分	答案字符串比对	仿真器任务成败判定
后训练前	准确率 0.095	成功率 40% ~ 50%
后训练后	准确率 0.44	成功率 60% ~ 67%
各自的坎	先学格式、再学正确	温度方向、状态遗忘、KL 锚定与早停

两列之间，算法一行未改——这正是第 2 节题眼”强化学习外环与策略本体解耦”的完整兑现。判断一个模型能不能套这个外壳，只看一件事：它能不能给出离散选择的干净 log 概率。

10.2 一条越走越宽的路

本讲的四个主角恰好排成一条路线图：SimpleVLA-RL 把 GRPO 搬上 VLA、证明路能走通；RLinf 把训练做成基础设施、把路修宽；我们自己的实验把算法内核抽出来、在单卡上走了一遍最小闭环； $\pi_{0.6}^*$ 则把它推进真实世界——那里没有问题重采，价值函数被重新请了回来，人类纠正走进了训练回路。

回望上一讲的算法地图，本讲的 GRPO 一族仍然站在 on-policy 策略梯度这条链的末端：数据采完、更新一次、旧数据作废。仿真里这只是慢；到了真机上，每一条轨迹都是真金白银，扔不起。 $\pi_{0.6}^*$ 用离线迭代给出了它的答案，而下一讲我们走另一条路：**off-policy 的价值方法**——SAC 把每一条历史经验都存进回放池反复使用，再配上人在环的纠正与守护，第一次把强化学习完整地放上真机，让 SO-101 在一小时内学会接触型任务。

一句话总结：GRPO 用组内相对优势替掉 critic、用可验证奖励替掉人工标注，而它对策略的全部要求只是“离散选择 + log 概率”——所以同一套后训练外壳，既能让 VLM 学会数数，也能把动作写成整数文本的 VLA-0 自我提升；仿真给了它问题重采的奢侈，真实世界则逼出了价值函数与人在环的回归。

参考资料

- [1] SHAO Z, WANG P, ZHU Q, et al. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models[EB/OL]. (2024-02-05). <https://arxiv.org/abs/2402.03300>.
- [2] DEEPSEEK-AI. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning[EB/OL]. (2025-01-22). <https://arxiv.org/abs/2501.12948>.
- [3] LIU Z, SUN Z, ZANG Y, et al. Visual-RFT: Visual reinforcement fine-tuning[EB/OL]. (2025-03-03). <https://arxiv.org/abs/2503.01785>.
- [4] DEEP-AGENT. R1-V: Reinforcing super generalization ability in vision-language models[EB/OL]. (2025). <https://github.com/Deep-Agent/R1-V>.
- [5] LI Z, WANG X, STENGEL-ESKIN E, et al. Super-CLEVR: A virtual benchmark to diagnose domain robustness in visual reasoning[EB/OL]. (2022-12-01). <https://arxiv.org/abs/2212.00259>.
- [6] BAI S, CHEN K, LIU X, et al. Qwen2.5-VL technical report[EB/OL]. (2025-02-19). <https://arxiv.org/abs/2502.13923>.
- [7] HUGGING FACE. TRL: Transformer reinforcement learning[EB/OL]. <https://github.com/huggingface/trl>.
- [8] GOYAL A, HADFIELD H, YANG X, et al. VLA-0: Building state-of-the-art VLAs with zero modification[EB/OL]. (2025-10-15). <https://arxiv.org/abs/2510.13054>.

- [9] LI H, ZUO Y, YU J, et al. SimpleVLA-RL: Scaling VLA training via reinforcement learning[EB/OL]. (2025-09-11). <https://arxiv.org/abs/2509.09674>.
- [10] KIM M J, FINN C, LIANG P. Fine-tuning vision-language-action models: Optimizing speed and success[EB/OL]. (2025-02-27). <https://arxiv.org/abs/2502.19645>.
- [11] BYTEDANCE. verl: Volcano engine reinforcement learning for LLMs[EB/OL]. <https://github.com/volcengine/verl>.
- [12] ZANG H, WEI M, XU S, et al. RLinf-VLA: A unified and efficient framework for reinforcement learning of vision-language-action models[EB/OL]. (2025-10-08). <https://arxiv.org/abs/2510.06710>.
- [13] LIU B, ZHU Y, GAO C, et al. LIBERO: Benchmarking knowledge transfer for lifelong robot learning[EB/OL]. (2023-06-05). <https://arxiv.org/abs/2306.03310>.
- [14] PHYSICAL INTELLIGENCE. $\pi_{0.6}^*$: A VLA that learns from experience[EB/OL]. (2025-11-18). <https://arxiv.org/abs/2511.14759>.
- [15] PENG X B, KUMAR A, ZHANG G, et al. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning[EB/OL]. (2019-10-01). <https://arxiv.org/abs/1910.00177>.
- [16] ABDOLMALEKI A, SPRINGENBERG J T, TASSA Y, et al. Maximum a posteriori policy optimisation[EB/OL]. (2018-06-14). <https://arxiv.org/abs/1806.06920>.
- [17] FRANS K, PARK S, ABBEEL P, et al. Diffusion guidance is a controllable policy improvement operator[EB/OL]. (2025-05-29). <https://arxiv.org/abs/2505.23458>.
- [18] KELLY M, SIDRANE C, DRIGGS-CAMPBELL K, et al. HG-DAGger: Interactive imitation learning with human experts[EB/OL]. (2018-10-05). <https://arxiv.org/abs/1810.02890>.
- [19] CHEN L, LU K, RAJESWARAN A, et al. Decision Transformer: Reinforcement learning via sequence modeling[EB/OL]. (2021-06-02). <https://arxiv.org/abs/2106.01345>.
- [20] SCHMIDHUBER J. Reinforcement learning upside down: Don't predict rewards - just map them to actions[EB/OL]. (2019-12-05). <https://arxiv.org/abs/1912.02875>.

本讲中的 VLM 数数前后对照图、VLA-0 成功率对照图与前后 rollout 抽帧对照图，均为本课程实验渲染。