

Off-policy 强化学习：从仿真提速到真机落地

目录

1 上一讲留下的账：真机上样本有多贵	2
1.1 我们已经见过的两种强化学习	2
1.2 换到真机，这笔账立刻算不平	3
1.3 为什么 PPO 做不到“攒着反复用”	3
1.4 本节小结	3
2 价值方法与 off-policy：把稀疏的成功传播开	4
2.1 行为策略与目标策略：off-policy 的定义	4
2.2 replay buffer：把经验存成资产	5
2.3 Q 函数：给「状态-动作」记账	6
2.4 动手：CartPole 上从查表到用网络	8
任务	8
第一版：表格 Q-learning	10
第二版：DQN	11
结果	11
2.5 天下没有免费的午餐：off-policy 的稳定性代价	13
2.6 与上一讲的分水岭：critic 请走了，又请回来	14
2.7 本节小结	14
3 连续动作的 off-policy：DDPG $\rightarrow$ TD3 $\rightarrow$ SAC	14
3.1 DDPG：Actor 出动作，Critic 打分	15
3.2 TD3：用两个 Critic 治高估	16
3.3 SAC：把探索变成一条原则	17
3.4 再往前一步：把 Critic 从一个数换成一条分布	18
3.5 本节小结	18
4 同一个 G1，换 off-policy 再走一遍：15 分钟学会走路	18
4.1 FastTD3 与 FastSAC：把 off-policy 搬进大规模并行仿真	18
4.2 结果：G1 行走，单卡 15 分钟	19

1 上一讲留下的账：真机上样本有多贵	2
4.3 动手实验：给 G1 行走加第四个版本	20
4.4 本节小结	23
5 真机压轴：HIL-SERL 让 SO-101 学会接触型任务	23
5.1 把 SAC 搬上真机：四道坎	24
5.2 一条血缘链：SAC 到 HIL-SERL	24
5.3 落到我们的硬件：角色分工与第一步——划安全边界	25
5.4 第一件套 demo buffer：示教打底，并采下示教	25
5.5 第二件套视觉奖励分类器：让相机当裁判，并把它训出来	26
5.6 第三、四件套人工干预与自动复位	26
5.7 actor-learner 架构：拼成在线系统，并跑起来	27
5.8 训练全景与真机战绩	28
5.9 没有真机：gym_hil 仿真替代	31
5.10 训练健康的体征：盯着干预率	32
5.11 本节小结	32
6 结课全景：三种强化学习，与一条完整的链路	33
6.1 三种 RL 形态对照	33
6.2 从第 8 讲到第 16 讲：一条链路	34
7 本讲小结	35
7.1 主线回顾	35
7.2 方法演进链	35
参考文献	35

1 上一讲留下的账：真机上样本有多贵

1.1 我们已经见过的两种强化学习

到目前为止，这门课里的强化学习都发生在两个“便宜”的地方。

第 14 讲，我们在 mjlal 仿真里让 G1 学会了行走和动作跟随：REINFORCE、A2C、PPO，一路把训练做稳。那套流程的底色是**大规模并行仿真**——4096 个环境同时跑，一次迭代就采回几万步经验，训练三千次迭代，累计消耗的环境交互在**上亿步**这个量级。仿真里这不算事：GPU 多算一会儿而已。

第 15 讲，我们用 GRPO 给 VLM 做后训练，也看了 SimpleVLA-RL 把同一套外壳搬到 VLA 的动作 token 上：同一道题采一组回答（或同一个初始状态采一组 rollout），组内比较出相对优势。它省掉了 critic，但没省掉采样——每一次更新都要新鲜采一组，而且**采完这一批、更新完就扔**。

这两讲有一个共同的隐含前提：**采样近乎免费**。也正因为免费，我们可以心安理得地用 on-policy 方

法——数据必须来自当前策略，旧数据一律作废。

1.2 换到真机，这笔账立刻算不平

现在把场景换成一台真实的 SO-101 机械臂，重新算这笔账：

- **时间**：一条操作轨迹 5 到 20 秒，加上复位、摆放物体，一分钟采不了几条。一整天不停地采，也就是几千条轨迹、几十万步交互——离“上亿步”差了三个数量级。
- **人力**：真机采样必须有人守着。机器人卡住要拉回来，物体掉了要捡，出危险要急停。
- **磨损与风险**：每一次失败的探索都在消耗硬件寿命；一次出格的动作可能撞坏夹爪或工件。
- **没有并行**：仿真里 4096 个环境是一行配置，真机上 4096 台机械臂是一座工厂。

所以在真机上，**每一条经验都很贵**。而 on-policy 方法的规矩是“数据只能用一次”——这相当于花大价钱买菜，做一顿饭就把冰箱清空。真机强化学习的第一原则由此而来：**经验必须攒着反复用**。

1.3 为什么 PPO 做不到“攒着反复用”

有同学会问：PPO 不是已经在“复用”了吗——同一批数据做多轮 minibatch 更新？

确实，但那是**小范围、短窗口**的复用（第 14 讲 7.3 节讲过）：PPO 的 ratio 和 clip 机制只在“数据来自**很接近当前策略**的旧策略”时才有效。数据一旦老了——比如是三天前的策略采的，或者干脆是人遥操作示教的——重要性比率会严重失真，clip 直接把梯度掐没。PPO 的复用是“这顿饭做完前菜可以再翻炒两次”，不是“冰箱里的菜下周还能吃”。

要真正做到“什么数据都能吃”——旧策略的、人示教的、别的策略采的——需要换一类从根上就不挑数据来源的算法。这正是第 14 讲 3.5 节那张分类地图上埋下的那条线：**off-policy（离策略）方法**。这一讲，我们把它请上场，并沿着它一路走到真机。

1.4 本节小结

本节把课程的场景从仿真切换到真机，核心是一笔账：仿真里采样近乎免费，on-policy“采完即弃”跑得起；真机上一条轨迹按十秒计费、要人陪着采、还有磨损风险，样本贵了三个数量级。PPO 的多轮 minibatch 只是近策略的短窗口复用，救不了这笔账。真机强化学习的第一原则是经验必须存起来反复用，这就把我们引向 off-policy 方法。

2 价值方法与 off-policy：把稀疏的成功传播开

2.1 行为策略与目标策略：off-policy 的定义

第 14 讲 3.4 节给过教材上的标准定义，这里正式启用它：

- **行为策略 (behavior policy)**：真正在环境里执行动作、产生数据的策略。
- **目标策略 (target policy)**：我们想要学好的那个策略。

on-policy：两者是同一个——学谁就用谁去采数据，所以数据随策略更新立刻过期。**off-policy**：两者可以不同——学的策略和采数据的策略解耦。

拿熟悉的例子对号入座。第 14 讲训 PPO 时，每一轮迭代都是**当前这一版策略**去 4096 个环境里采数据，更新完策略，这批数据立刻作废——行为策略与目标策略始终是同一个，这是 on-policy。而这一讲要做的事是：目标策略在 GPU 上不停更新，可它训练用的数据，可能来自十分钟前的旧版本策略、来自人拿 leader 臂做的示教、甚至来自训练中人接管的那几下——**采数据的“手”和被训练的“脑”不再是同一个**，这是 off-policy。

第 14 讲 3.4 节那张数据流对比图现在可以回头再看一眼：左半就是第 14 讲每天在做的循环——采样、更新一次、作废、重采，数据在“当前策略”和“新鲜数据”之间打转，出不了这个圈；右半是本讲的新世界——三种来源的经验全部汇入中间的经验池，目标策略从池里随机抽 batch 训练，策略更新不作废任何数据，新经验只是继续入池。两半放在一起看，off-policy 多出来的其实只有一样东西——**中间那个池子**，但正是它让“数据”从消耗品变成了资产。

	on-policy	off-policy
本课出现在	第 14 讲、第 15 讲	本讲
谁采数据	当前策略本人	谁都行：旧策略、人、别的策略
数据寿命	一次更新后作废	长期有效，反复使用
策略更新后	必须重新采样	继续吃老本
样本效率	低	高
训练稳定性	高（数据永远新鲜）	需要额外手段兜底（2.5 节）

解耦这一步看似只是定义上的松绑，实际上打开了三扇门，这一讲后面全都要用到：

1. **旧数据能用**：过去所有版本的策略采的经验都还有效。
2. **示教能用**：人遥操作采的成功示教，本质上就是“另一个行为策略”产生的数据。
3. **干预能用**：训练中人接管机器人纠偏的那几步，同样是合法数据——这是本讲后半场 HIL-SERL 的核心素材。

三扇门后面是同一间仓库，先看仓库本身。

2.2 replay buffer: 把经验存成资产

off-policy 的标配数据结构是**经验回放池 (replay buffer)**。它做的事情非常朴素——但每个设计都有明确的理由：

- **存什么**：不存完整轨迹，而是把经验拆成一条条**转移** (s, a, r, s', d) ——状态、动作、即时奖励、下一状态、是否终止。拆散了存是有意为之：下一小节会看到，off-policy 的学习单元恰好就是单条转移，不需要知道它前后发生了什么。
- **存多少**：容量通常在几十万到上百万条转移，先进先出。对真机训练来说这个容量近乎“终身记忆”——几小时的真机交互也就几万条转移，一条也不必扔。
- **怎么取**：训练时从池子里**均匀随机**抽一个 batch。随机抽样不只是省事，它本身就是一个稳定器：同一条轨迹里相邻的转移高度相关（机械臂这一拍和下一拍的画面几乎一样），按时间顺序喂给网络等于反复用相关样本冲刷梯度；随机打散后，一个 batch 里混着不同回合、不同阶段、不同来源的转移，梯度估计干净得多。

池内经验（按时间存放）




图 1: 经验池的存与取：上排为按时间存放的池内转移（来源成片、相邻相关），下排为随机抽出的一个 batch（时刻与来源全打散）

上图把“存”和“取”画在了一起。上排是池子的真实存放顺序：按时间一条条排过去，同一段颜色（同来源、同一回合）连成片，相邻两条转移几乎长一样。下排是训练时真正喂给网络的一个 batch——从池子里随机翻牌抽出来，灰色的连线指出每一条原本躺在池子的哪个位置：八条在池子里彼此隔得老远，来源也混着，三种颜色都进了这一把。网络每一步看到的都是这样一把“混装”的经验，梯度自然稳。

对照第 14 讲的 PPO 就能看清差别：PPO 的“数据仓库”每轮清空重建，本质是**缓冲区**；replay buffer 只进不清（满了才挤掉最旧的），是真正的**资产**。HIL-SERL 还会维护两个池子——在线经验一个、人类示教一个——那是第 5 节的事，机制完全相同。

2.3 Q 函数：给「状态-动作」记账

off-policy 为什么能不挑数据来源？根子在它学的东西不一样。策略梯度直接学“该做什么”，而价值方法先学“做了会怎样”。

第 14 讲 2.4 节我们已经认识了价值函数 $V(s)$ ——“从状态 s 出发平均还能拿多少回报”。但 V 有个先天短板：它把“之后会怎么做”整个托付给了某个策略，所以它天生绑定那个策略——换个策略，同一个状态的 V 就变了，旧策略采的数据也就没法直接给新策略估 V 。off-policy 需要一个更“钉得死”的对象：把**第一步的动作也固定下来**——

$$Q(s, a) = \text{从状态 } s \text{ 做动作 } a \text{ 出发, 之后平均还能拿多少回报}$$

Q 比 V 多钉住一个动作，好处立竿见影：一条数据 $(s, a, \dots)$ 里的 s 和 a 都是**既成事实**，不管这个 a 是谁选的——旧策略、人手、随机探索——“在 s 做了 a ”这件事对任何人都是同一件事。评价既成事实，不需要征得当事策略的同意。

写成式子就是：

$$Q^\pi(s, a) = \mathbb{E}_\pi[r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots \mid s_t = s, a_t = a]$$

逐段读一遍：等号左边是“这个状态-动作对值多少”；右边的期望是“未来能拿到的折扣回报”；竖线后面挂着两个条件——**从状态 s 出发，并且第一步做动作 a** ；而期望下标的 π 在提醒我们，第一步之后的每一步仍然按策略 π 走。和第 14 讲 6.2 节的 $V^\pi(s)$ 相比，唯一多出来的就是“第一步做了 a ”这个条件。

这个 Q 函数不是靠完整轨迹的总回报学的，而是靠**自举 (bootstrap)**——用下一步的估值来更新这一步（第 14 讲 6.3 节我们用它区分过 REINFORCE 和 Actor-Critic）。对每一条转移记录 (s, a, r, s') ， Q 应该满足：

$$y = r + \gamma(1 - d)Q(s', a'), \quad a' \sim \pi(\cdot \mid s')$$

符号	含义	典型取值
(s, a, r, s')	一条转移：状态、动作、即时奖励、下一状态	来自 replay buffer
y	$Q(s, a)$ 的更新目标	—
γ	折扣因子	0.99
d	回合是否在 s' 终止（终止则不再有后续回报）	0 或 1
a'	由 当前策略 在 s' 处选出的下一动作	—

注意这个等式的一个关键性质：它对**任何来源**的转移 (s, a, r, s') 都成立。这条转移是三天前的旧策略采的、是人示教的、还是干预时人打的方向，都不影响“ s 做 a 得了 r 到了 s' ”这个事实——下一步的

动作 a' 用当前策略重新选就行。这就是 **off-policy 能吃百家饭的数学根源**：贝尔曼等式描述的是环境的因果，而不是某个策略的偏好。

价值方法还有一个对真机特别重要的本事：**把稀疏的成功传播开**。真机任务的奖励往往只有“最后成没成功”一个 0/1 信号（第 5 节会看到它甚至是学出来的）。策略梯度面对这种奖励几乎摸不到方向；而 Q 函数靠自举，能像多米诺骨牌一样把终点的信号一格一格传回起点。

用一个迷你例子把“传播”演出来。假设推方块任务的一个成功回合只有三步，产生三条转移进池子 ($\gamma = 0.9$, Q 初始全为 0)：

转移	内容	奖励
甲	$(s_0, a_0, 0, s_1)$: 伸向方块	0
乙	$(s_1, a_1, 0, s_2)$: 抵住方块推	0
丙	$(s_2, a_2, 1, \text{终止})$: 方块进目标区	1

训练时反复从池子里随机抽转移，看 Q 值怎么演化：

- 第一次抽到**丙**：终止转移，目标 $y = 1$ ，于是 $Q(s_2, a_2)$ 朝 1 更新——成功本身先被记住。
- 之后抽到**乙**：目标 $y = 0 + 0.9 \times Q(s_2, a_2) \approx 0.9$ ——虽然乙自己的奖励是 0，但“它通向一个值 1 的地方”这件事通过自举传了过来， $Q(s_1, a_1)$ 朝 0.9 涨。
- 再抽到**甲**：同理 $Q(s_0, a_0)$ 朝 $0.9 \times 0.9 \approx 0.81$ 涨。




图 2: 一个终点奖励沿转移链回传成价值坡道：抽到丙记住成功，再抽到乙、甲时价值按 γ 折扣逐格向起点传播。 $\gamma = 0.9$ ，起点三个 Q 全为 0

上图把这三轮抽样画成了柱状图：横轴三组分别是 $Q(s_0, a_0)$ 、 $Q(s_1, a_1)$ 、 $Q(s_2, a_2)$ ，同一组里从浅到深是抽样进行到第几轮（起点三个 Q 全是 0，那一档没有柱子可画，写在标题里）——抽到丙之后只有最右边那组立了起来（值 1），再抽到乙时中间那组跟着涨到 0.9，最后抽到甲，最左边那组涨到 0.81。

柱子上方那两道带 $\times \gamma$ 的箭头，画的就是**每往左传一格要乘一次折扣**；右侧已经学到的高度则一直保持不变。几轮下来，一个孤零零的终点奖励就被摊开成了一条**从起点到终点逐渐升高的价值坡道**，后面的 actor 只要顺着坡爬就行。注意整个过程对抽样顺序、对这三条转移是谁采的都没有要求——早抽到乙也没关系（那时目标还是 0，等丙学进去后乙迟早会被再次抽到）；池子里随机翻牌，信号自然回流。

备注：目标 y 里还有一个不起眼但关键的工程件——**目标网络**。如果 y 里的 $Q(s', a')$ 用的是正在被训练的同一个网络，那么每次参数更新，所有目标值都跟着晃，网络等于在追自己的尾巴。实践中会维护一份**延迟拷贝** $\bar{Q}$ 专门算目标：每步只让它朝主网络挪一小步（软更新，比例 $\tau \approx 0.005$ ）。目标稳住了，回归才收敛。上面公式里的 $Q(s', a')$ ，实现中都读作 $\bar{Q}(s', a')$ 。

2.4 动手：CartPole 上从查表到用网络

前面 Q 函数、经验池、目标网络都还是纸面概念。在上真机、上机械臂之前，先用一个最小的任务把它们**跑成代码**——经典的 CartPole：一根杆立在小车上，左右推车让杆不倒，动作只有“左推 / 右推”两个离散选项。它简单到能在几分钟内训完，却正好能把“从查表到用网络”这一步演清楚。

任务

先把这个场景在脑子里立起来：一辆小车卡在一条水平轨道上，只能左右滑；车顶有一个**不受驱动的转轴**，一根杆子铰在上面。没有任何电机去扶那根杆——它只受重力和小车加速度的摆布。策略唯一能做的事就是**把车往左推或往右推**，靠车身的移动把杆一次次“接”回竖直附近。这也是它反直觉的地方：想让杆往右倒回来，你得先把车往右推。

- **观测**：四个连续量——小车位置、小车速度、杆的角度、杆的角速度。
- **动作**：两个离散选项——左推、右推。**没有“不动”这一档**，每一拍都必须选一边。
- **奖励与终止**：每活一步得 1 分。杆偏离竖直超过约 12° （弧度约 0.21）、或小车滑出轨道 ± 2.4 ，回合立即结束；撑满 500 步则回合正常结束，拿满分 500。所以“回合回报”和“杆立住了几步”是同一个数。
- **什么算成功**：单回合 500 分叫**满分**，但真正的门槛是**稳定拿满分**——后面会看到，“偶尔打出一次 500”和“最后 50 个回合大多是 500”是两回事。

先看这个环境自己渲出来是什么样，三帧分别对应上面说的那两道终止线：

画面里看不到那两道终止线——它们是判定用的数值，不是场景里的物体。下面这张示意图把它们和四个观测量一起标出来：

选它当入门例子有三个具体理由：状态只有四维，**表格法勉强还做得动**，这才谈得上和 DQN 同台对照（换成机械臂，表格法连起跑线都站不上）；纯 CPU 几分钟就能训完一轮，不需要仿真器也不需要机器人；而它的观测是连续量、动作是离散档，恰好卡在“必须分桶”和“可以用网络”的分界线上——这一节要讲的就是这条线。




图 3: 真实渲染出的 CartPole 三帧 (环境自带渲染器, 非示意图): 黑色方块是小车, 浅色细杆铰在车顶, 贯穿画面的横线是轨道。左: 杆基本竖直, 回合继续。中: 杆偏到 11.5° , 再歪半度就撞上 12° 那道线。右: 小车滑到 2.2, 再滑一点就出 ± 2.4 的轨道范围




图 4: CartPole 的两道终止线与那个反直觉的动作方向。左半把上面四条要素画进同一个场景: 红色虚线是轨道两端的 ± 2.4 , 越过就出界; 橙色扇形是竖直方向左右各 12° (0.21 rad) 的可用范围, 杆尖越出扇形回合当场结束——两道线卡的不是同一件事, 一道管车能滑多远、一道管杆能歪多少。车顶那个白心圆是**自由转轴**, 没有电机, 杆只受重力和车身加速度摆布。(1)(2)(3)(4) 分别标出四个观测量各自对应的物理量。右半是那一下反直觉的动作: 杆已经倒到 11° , 正确的做法是把车也**往右推**, 让车追到杆的正下方, 杆才回正; 往左“顶回去”只会让它倒得更快。动作只有 0 / 1 两档, 没有“不动”这一档

两个版本用同一个任务、同一套统计口径（回合回报），版本之间的差异就是这一节的知识点。

第一版：表格 Q-learning

最朴素的做法是给每个“状态-动作”配一格账，存成一张表。可连续值没法当表格的下标——于是第一步永远是**分桶**：每一维切成 8 段，四维组合起来就是表的“状态”维度（ $8^4 \times 2$ 格）。然后就是上一节那套 Q 更新，逐格填表， ϵ -greedy 采样（大概率按当前最优、小概率随机试）：

```
# 四维桶索引接上动作号，拼成五元组——它就是这张表里唯一一格的下标
cell = tuple(state.tolist()) + (int(action),)
# 只用 next_state 的四维索引取出"下一状态那一行"，再取 max:
# Q-learning 学的是"下一步按最优走"，与这一步实际怎么采样无关，off-policy 由此而来
best_next = self.model.table[tuple(next_state.tolist())].max()
# (1.0 - done): 回合终止时后面没有"下一步"了，把 bootstrap 项整个乘没
target = reward + self.gamma * best_next * (1.0 - done)
td_error = target - self.model.table[cell]      # 目标与现值之差，就是这一格错了
↪ 多少

# 这一行就是表格 Q-learning 的全部：把这一格往目标挪 ALPHA 那么多。
self.model.table[cell] += self.alpha * td_error
```

这一版**没有神经网络**——“没有网络”本身就是暴露的教学点。Q 表照样放进一个 `nn.Module`，只为了和下一版的 `QNetwork` 占同一个位置、能用同一套 `state_dict()` 存取；但里面一个可训练参数都没有，整张表只是个 buffer：

```
def __init__(self, n_actions):
    super().__init__()
    # register_buffer: 随模型保存/加载，但不是可训练参数。
    self.register_buffer("table", torch.zeros((NUM_BINS,) * 4 + (n_actions,)))
    self.n_actions = n_actions
```

没有参数就没有梯度，也就没有优化器可配——`configure_optimizers` 直接返回空：

```
def configure_optimizers(self):
    # 查表更新不是梯度下降，这里确实没有优化器可配。
    return None
```

表格法的致命短板是：状态得手工分桶，而表的大小是**每维桶数的连乘**。四维还能勉强切，换成图像或机械臂几十维的状态，桶数直接组合爆炸、根本存不下——这就是“维度诅咒”。

第二版: DQN

解法是把那张表换成一个**神经网络**: 输入原始连续状态, 输出每个动作的 Q 值。这就是 DQN[1]——2015 年它靠这一招在 Atari 游戏上直接吃屏幕像素打到人类水平, 把值学习从表格时代推进到了网络时代。网络能在相近状态之间**泛化**, 不用穷举分桶, 天然绕开维度爆炸——这种“用一个可学习的函数去近似整张 Q 表”的做法叫**函数近似**。

但网络不能像表格那样即采即改: 训练样本前后高度相关、更新目标自己还在动, 直接套表格那套会训崩。于是把上两节攒下的两件工程配件正式装上——**经验回放** (2.2 节, 随机抽 batch 打断相关性) 和 **目标网络** (2.3 节备注, 稳住回归目标)。三处改动一目了然:

```
# 网络一次吐出全部动作的 Q 值, gather 按实际执行的那个动作号把对应列挑出来
# ——相当于表格版的 table[cell], 只是现在这一格是算出来的, 不是查出来的
q_values = self.online(states).gather(1, actions.unsqueeze(1)).squeeze(1)
with torch.no_grad():          # 目标是常数, 不能让梯度顺着它流回目标网络
    # 采集时 dones 写的是 terminated (不含 truncated),
    # 所以真正失败才不 bootstrap, 这里直接乘 (1 - dones)。
    next_q = self.target(next_states).max(dim=1).values      # 用 target 网络,
    ↪ 不是 online
    td_target = rewards + self.gamma * next_q * (1.0 - dones)
    # 表格版是" 把这一格挪一点", 这里换成对整批做一次回归——梯度下降替代了直接赋值
    loss = nn.functional.mse_loss(q_values, td_target)
```

对着上一版读: Q 值的来源从 table[s] 变成了 online(s), 查表变成了前向计算; 算目标用的是 self.target 而不是 self.online, 一份延迟拷贝专门负责给出回归目标, 网络不再追自己的尾巴; 最后, 更新不再是改表里的一格, 而是对一整个 minibatch 做回归——而这个 batch 来自经验池的随机抽样, 正好把同一条轨迹上前后相邻的样本打散。

(想把 DQN 这一档再练熟一点, Hugging Face 的深度强化学习课 [2] 有一整个单元配可跑的练习。)

两版的四件套骨架是同一副: 一个边跑环境边吐样本的 Dataset、一个 LightningDataModule 持有环境、一个 nn.Module 装 Q (v1 是表、v2 是网络)、一个 LightningModule 写更新规则, 入口都是 trainer.fit(model, data)。差别不在骨架, 在骨架里换掉的那几个零件: Q 从表变成网络、多出一份目标网络、多出一个 ReplayBuffer 类 (v1 的样本是采一条学一条, 用不上池子), 以及多出一个真正的优化器——v1 那个返回 None 的 configure_optimizers 到这一版才有东西可配, 因为到这一版才有可训练参数。换零件不换骨架, 正是这条阶梯往后四级还能一直用同一副模板的原因。

结果

两版各跑一次, 横轴统一用环境步数 (两级的回合长度差很多, 按回合数对齐会误导):




图 5: CartPole 两级值学习的回合回报对照: v1 表格 Q-learning 跑满 20 万步也没稳住, 滑动均值到约 3.6 万步才第一次站上 100 分, 此后在 100 ~ 350 分之间大幅起落、8 万步前还数次跌回 100 以下, 末 50 回合均值收在 193 分; v2 DQN 约 3 万步就打出第一个 500 分满分回合, 5 万步收工时末 50 回合里已有 31 个满分。两次训练的原始回报记录都在 `code/r1/3_offpolicy/result/` 下, 这张图由它们重画而成

版本	方法	Q 的表示	环境步数	末 50 回合平均 回报	其中满分回合
v1	表格 Q-learning	查表, 状态手工分桶	20.1 万	193	0 / 50
v2	DQN	网络, 吃原始状态	5.0 万	396	31 / 50

差距很干脆: DQN 只用了表格法四分之一的交互, 成绩却是它的两倍。末段的质量差得更远——DQN 最后 50 个回合里有 31 个直接打满 500 分, 表格法这 50 个回合一个满分都没有, 最好的一次只到 452。

图上那几根伸到 500 分那条虚线的浅蓝细线不是错觉: 表格法整个 20 万步里也打出过 6 次满分 (第一次在约 9.8 万步)。但它守不住——满分回合零星出现, 下一个回合又掉回一两百分。“偶尔做到”和“稳定做到”是两件事, 这条分界线在后面 SO-101 的实验里还会再出现一次。

原因就在分桶。每维只切 8 段, 落进同一个桶的状态被当成同一个状态——杆子偏 3° 和偏 8° 共用一格 Q 值, 策略再怎么训也精细不到哪去; 而且相邻桶之间没有任何信息共享, 每一格都得自己撞够次数才学得会。DQN 的网络恰恰相反: 相近的状态天然给出相近的 Q 值, 一次更新就能惠及一片邻域, 所以又快又稳。

这就是“函数近似”四个字的实际含义：不是换了个更聪明的更新公式，而是换了一种“记住经验”的方式——记得越会举一反三，同样的交互量就换得回越高的回报。

不过省样本从来不是白省的。函数近似、自举、off-policy 这三样一旦凑齐，训练就失去了“只会越来越好”的保证——下一节就来算这笔账。

到这里，Q 函数、经验池、目标网络都从概念变成了能跑的代码。但 DQN 还卡着一道坎：它靠“对每个动作的 Q 取 `argmax`”来选动作，这只在动作是有限几个离散选项时才做得到。机械臂的动作是六个关节各自转多少的连续量——`argmax` 无从枚举。要把 off-policy 带上机械臂，就得换一类“不靠 `argmax`、直接吐连续动作”的算法。而在动手爬这条连续控制的阶梯之前，还得先认清 off-policy 省下样本要付的那份代价。

2.5 天下没有免费的午餐：off-policy 的稳定性代价

既然 off-policy 这么省样本，第 14 讲为什么不直接教它？因为它天生更难训稳。强化学习里有个著名的“死亡三角”（deadly triad，这个名字出自 Sutton 与 Barto 的教材 [3]）：自举、函数近似（神经网络）、离策略数据——三者单独都没事，凑齐了就容易让训练发散：

组合	熟悉的例子	稳吗
只有函数近似	监督学习	稳：标签固定，回归目标不动
自举 + 离策略，无函数近似	表格型 Q-learning（每个状态一格）	稳：有收敛保证
函数近似 + 自举，on-policy	第 14 讲 A2C/PPO 的 critic	基本稳：数据新鲜，错账很快被重访修正
三者齐	深度 off-policy（本讲）	要靠工程兜底

三者凑齐为什么危险？直觉是：Q 用自己的估值更新自己（自举），估值本身有误差（网络近似），而离策略数据又让“账本出错的地方”和“账本被查账的地方”错开——网络在池子里那批旧数据上改账本，改动却会牵连到当前策略常去的状态（函数近似让相邻状态的估值联动），那些地方的错误迟迟等不到新数据来纠正，误差就可能越滚越大。

on-policy 方法（PPO）用“只吃新鲜数据”砍掉了第三条边，所以稳，代价是费样本；off-policy 方法三条边全占，所以省样本，代价是要靠一堆工程手段兜底。这些兜底手段——双 Q 取小（治高估）、目标网络软更新（治追尾巴）、随机抽样（治样本相关）、合适的更新采样比（UTD, update-to-data ratio, 即每采一步数据做几次梯度更新，治更新过猛）——下一节起会逐个登场，每一件都对着死亡三角的某一条边。它们不是装饰，本讲后面的方法（DDPG、TD3、SAC、HIL-SERL）都带着这样一串“稳定性配件”。

2.6 与上一讲的分水岭：critic 请走了，又请回来

第 15 讲我们刚把 critic 请走（GRPO 用组内平均分当基线），这一讲怎么又请回来了？对照一下两边的处境就清楚了：

	第 15 讲	第 16 讲
场景	GRPO 后训练	真机 RL
动作	离散 token，一次生成一段	连续控制量，10 Hz 逐步闭环
奖励	可验证：规则一判就有	稀疏 0/1，还得靠视觉判
一组采样的成本	便宜（GPU 上采一组回答）	昂贵（真机跑一组 rollout）
数据能否复用	不复用也无妨	必须复用
基线/信号	组内比较就够	要靠 Q 自举把稀疏信号传开

GRPO 免 critic 的前提是“同题采一组很便宜”；真机上一组 rollout 本身就是最贵的东西，而且连续动作加稀疏奖励，光靠组内比较传播不了信号。所以 critic 回来了，而且这次它是主角：**off-policy** 的一切复用能力，都建立在 Q 函数这本“不挑数据来源的账”上。

2.7 本节小结

本节建立了这一讲的方法底座。off-policy 的定义是行为策略与目标策略解耦，由此旧数据、人类示教、人工干预都成为合法训练数据，统一存进 replay buffer 这座“资产仓库”随机取用；数学根源是 Q 函数评价的是“在 s 做了 a ”这个既成事实，贝尔曼等式对任何来源的转移都成立。 Q 靠自举把稀疏的成功信号沿价值坡道一格格传回起点，目标网络稳住回归目标。我们在 CartPole 上把这套概念跑成了代码——从手工分桶的表格 Q ，到用神经网络吃原始状态的 DQN，“函数近似 + 经验回放 + 目标网络”就此凑齐。但 DQN 靠 $\arg\max$ 选动作，迈不进连续控制；而三者一凑齐，死亡三角带来的稳定性风险也一并到场。接下来一节把连续动作这道坎补上：DDPG、TD3、SAC 一级一级往上走——这也是为什么入门先学 on-policy，上真机才换 off-policy。

3 连续动作的 off-policy: DDPG $\rightarrow$ TD3 $\rightarrow$ SAC

前面 CartPole 上的 DQN 有一个天花板：它靠“对每个动作的 Q 值取 $\arg\max$ ”来选动作，这只在动作是**有限几个离散选项**时才做得到。机械臂的动作是六个关节各自转多少的连续量（每一步给每个关节一个目标角度增量），把连续区间切成格子再 $\arg\max$ ，格子数随维度指数爆炸——和上一节表格 Q 撞的是同一堵墙。要在连续动作空间里做 off-policy，得换一个思路：不再“评分选最高”，而是**直接让一个网络吐出动作**。

这一节把连续动作的 off-policy 一次讲完：DDPG 打地基，TD3 补它高估的毛病，SAC 换掉它太弱的探索，最后再看一个把 Critic 从“一个数”升级成“一条分布”的做法。**每一级只补上一级的一个短板**，这个递进关系本身就是要记住的东西。

这一节只讲机制，不带实验曲线。原先这里挂着一组 SO-101“够到方块”的四级对照实验，可那个单相机场景随仿真器重构下线了，图里的数既无法复现也无法逐点核对，所以整组撤下——留一张核不了的截图，不如先不留。等仿真器上的任务重建完，会带着可复现的原始记录重新补回来。**这一讲能动手跑、且有记录可核对的实验在上一节 (CartPole) 和下一节 (G1 行走)。**

3.1 DDPG: Actor 出动作, Critic 打分

DDPG (Deep Deterministic Policy Gradient, 深度确定性策略梯度) [4] 的骨架是两个网络:

- **Actor** (确定性策略): 输入状态, 直接输出一个确定的动作 (六个关节这一步各转多少), 末端用 $\tanh$ 把动作压进合法区间。它不像上一讲 PPO 那样输出一个概率分布再采样, 而是“看到这个状态, 我就做这个动作”。
- **Critic** (Q 网络): 输入“状态 + 动作”, 输出一个标量 Q 值, 即“在这个状态做这个动作, 预计能拿多少回报”。这就是上一节 Q 函数的连续版——DQN 的 Q 网络对每个离散动作出一个分, DDPG 的 Critic 直接把动作当输入吃进去出一个分。

两者怎么配合训练?

- **Critic 学法和 DQN 一脉相承**: 用贝尔曼目标 $r + \gamma Q_{\text{target}}(s', \pi(s'))$ 做回归, 只是下一动作由 Actor (而非 $\arg\max$) 给出, 同样配一套缓慢跟随的目标网络。
- **Actor 学法是 DDPG 的点睛之笔, 叫确定性策略梯度**: Actor 要让 Critic 给自己打的分越高越好, 于是损失就是 $-Q(s, \pi(s))$ 。梯度顺着 Critic 一路回传到 Actor——**Critic 告诉 Actor“往动作空间的哪个方向挪, 我给的分会更高”, Actor 就照着挪。**

探索呢? 确定性策略自己不带随机性, DDPG 靠在输出动作上**外加一点高斯噪声**来试探周围。记住这个“外加噪声”——它后面会成为这条阶梯的命门。

这张图把 DDPG 一轮更新的角色摆在了一起, 顺着箭头走一遍就是一轮训练: 环境给出状态 s , Actor 据此吐出动作, 交互产生的新经验进 replay buffer (灰箭头); 训练时从池子里抽一个 batch 交给 Critic (橙箭头); Critic 把自己的 $Q(s, a)$ 往右下那个贝尔曼目标 y 上回归 (绿箭头); 最后那条从 Critic 直接指回 Actor 的红箭头——**这就是确定性策略梯度**, Critic 打的分反过来告诉 Actor 该往动作空间的哪个方向挪。

图上有一件公式看不出来的事: **这几个角色围成的是一个闭环, 而不是一条流水线**。Actor 的更新方向取决于 Critic 此刻的打分, Critic 的回归目标又取决于 Actor 此刻给出的下一动作 $\mu'(s')$ ——两个网络互为对方的老师。下面这个毛病, 根子就在这个闭环上。

DDPG 的毛病是它只有一个 Critic。确定性策略梯度让 Actor 死命往“Critic 打分最高”的方向挪, 可单个 Critic 会**系统性地高估** Q 值——它对某些动作给出虚高的分, Actor 就一头扎过去, 扎过去才发现回报没那么高, 于是又调头。高估 $\rightarrow$ 追高 $\rightarrow$ 修正 $\rightarrow$ 再高估, 训练就在这种自我欺骗里反复横跳。

备注: 拿原始观测直接喂这个 Actor 有一个很容易撞上的坑。观测里某些分量的数值可能大




图 6: DDPG 的 Actor-Critic 分工: actor 直接吐出连续动作 $a = \mu(s)$, critic 学 $Q(s, a)$ 并沿 $\nabla_a Q$ 指导 actor (图上那条红箭头); 与 A2C 相反, 这里 critic 是学习主体

到几十上百 (位姿读数一类), 逐层放大到末端 $\tanh$ 时早已**深度饱和**, 而 $\tanh$ 在饱和区梯度几乎为零——梯度在这里被掐断, Actor 就冻在初始值上, 表现是“平均奖励一条死平线、参数一位小数都不动”。修法是标准动作: **观测归一化**, 在线统计每一维的均值方差, 归到零均值单位方差再喂网络。第 14 讲那套 G1 代码里就带着它——第 14 讲 4.5 节的代码地图指出的那个共用 `model.py`, 三个版本的归一化都在里面。这条对**任何**拿原始观测喂 MLP 的连续控制都成立; 有些实现改用 `LayerNorm` 把归一化直接长进网络结构里, 效果一样。诊断这类“怎么训都不涨”的顺序值得记住: 先排除训练预算, 再定位是哪个网络没在动, 再顺着零梯度找数值根因。

3.2 TD3: 用两个 Critic 治高估

TD3 (Twin Delayed DDPG, 双 Q 延迟更新版 DDPG) [5] 不是另起炉灶, 而是在 DDPG 上**打三个补丁**, 专治上一节那个“单 Critic 高估导致震荡”的毛病。三个补丁里最核心的一个, 名字就写在算法里——Twin, 双 Critic。

对照 DDPG, TD3 只改了三处, 其余骨架 (确定性 Actor、确定性策略梯度、目标网络、外加探索噪声) 原封不动:

1. **双 Critic 取小 (Clipped Double Q)**: 训**两个**独立的 Critic Q_1, Q_2 , 算贝尔曼目标时取两者中**较小的那个**: $r + \gamma \min(Q'_1, Q'_2)$ 。道理很直白——一个 Critic 可能虚高, 但两个网络在同一个动作上**同时**虚高的概率低得多, 取 $\min$ 就把高估的那部分系统地压下去。这是三补丁里最管用的

一条。

2. **延迟策略更新**: Critic 每更新若干步, Actor 才更新一次。让 Critic 先把 Q 估得准一点, 再拿它去指导 Actor, 避免 Actor 追着一个还没学好、乱跳的 Critic 跑。
3. **目标策略平滑**: 给目标动作加一点截断的小噪声, 避免 Critic 在某个动作上出现尖锐的虚高峰值被 Actor 钻空子。

但三个补丁动的全是 **Critic** 那一侧。TD3 的 Actor 依然是**确定性的**, 探索依然靠**外加的那点高斯噪声**——确定性策略加一点小噪声, 在六维动作空间里翻来覆去就那么大范围。**双 Critic 不是万能药**, 它只解决高估这一类问题; 探索的天花板还在那儿。那是 SAC 的地盘。

3.3 SAC: 把探索变成一条原则

DDPG 和 TD3 卡在同一个地方——确定性策略 + 外加噪声, 探索太弱。SAC (Soft Actor-Critic, 柔性演员-评论员) [6] 从根上换掉这套探索: 它让策略重新变成**随机的**, 并且把“保持随机、多探索”写成训练目标的一部分。

普通强化学习的目标只有一条: 回报最大化。SAC 在它上面加了一项——**策略熵最大化**。熵衡量策略的随机程度: 熵高, 策略在多个动作间保持犹豫、乐于尝试; 熵低, 策略趋于孤注一掷。SAC 的目标变成“**在拿高回报的同时, 尽量保持随机**”。这一项的作用正是治探索: 它不让策略过早锁死到某一套确定动作上, 而是逼着它持续在动作空间里铺开试探。DDPG/TD3 是“选定一个动作 + 抖一抖”, SAC 是“维持一整个动作分布, 且刻意不让它塌缩”——后者的探索强度不是一个量级。

把 SAC 拆开, 是四个零件 (对照 DDPG/TD3 看差异):

1. **随机策略 (挤压高斯 Actor)**: Actor 不再输出一个确定动作, 而是输出一个高斯分布的均值和标准差, 动作从中采样、再用 $\tanh$ 压进合法区间。有了分布, 才谈得上熵。
2. **最大熵目标**: 回报项里减去一个“熵的代价”, 等价于奖励策略保持随机。
3. **自动温度 α** : 熵这一项占多大权重, 用一个可学习的温度系数 α 自动调——训练自己找“探索够用又不过头”的平衡, 不用手调。
4. **双 Critic 取 min**: 治高估这条从 TD3 继承下来, SAC 也用两个 Critic 取小。

零件	DDPG	TD3	SAC
策略	确定性	确定性	随机 (高斯采样)
探索	外加噪声	外加噪声	最大熵内生
温度 α	无	无	自动调
Critic	单个	双 min	双 min

看这张表就清楚: SAC = TD3 的双 Critic + 一套全新的“随机策略 + 最大熵 + 自动温度”探索机制。前两级在 Critic 那侧修修补补, SAC 终于动了**策略**这一侧。

这条阶梯想让你带走的判断是: **在需要精细试探才能碰到成功的任务上, 卡住确定性策略的往往不是高估、也不是网络容量, 而是探索本身**。把距离一点点磨小和真正跨过“做成”那道坎, 是两件事——前

者靠 Critic 修得更准，后者要靠探索方式的质变。这个判断在下一节 G1 行走的实验里会以另一种形式再出现一次；专门支撑它的那组操作任务对照实验，等仿真器重建后补。

3.4 再往前一步：把 Critic 从一个数换成一条分布

上面三级的 Critic 都是估一个标量 Q 值。还有一路做法换了个思路 [7]：不估“预期回报是多少”，而是估“回报落在各个取值上的概率分布长什么样”——把可能的回报切成一排固定的档位，网络输出的是“落在每一档的概率”，训练时用分类交叉熵去拟合，而不是对一个数做均方误差。这类 Critic 一般叫**分布式 Critic**，档位数是个超参。

直觉上，回报本身是有不确定性的——同一个状态动作，运气好回报高、运气差回报低。硬压成一个平均数会丢掉这层结构；让网络直接去学整条分布，每一步更新提供的训练信号更丰富，训练往往也更稳。它不是这条阶梯的必修课，但值得认识：下一节那套把 off-policy 搬进大规模并行仿真的配方，论文里就带着分布式 Critic（4.3 节会说到，我们的课堂版刻意没上它）。

3.5 本节小结

这一节把连续动作的 off-policy 讲完了。DDPG 用一个确定性 Actor 直接吐连续动作、一个 Critic 打分，靠确定性策略梯度让 Actor 沿 Critic 的梯度往上爬，把 off-policy 从离散动作推进到了连续控制；代价是单个 Critic 会系统性高估，Actor 追着虚高的分反复横跳。TD3 打三个补丁——双 Critic 取 min、延迟策略更新、目标策略平滑——治住高估，但动的全是 Critic 那一侧，探索仍是“确定性动作加噪声”。SAC 换掉探索本身：随机策略 + 熵最大化 + 自动温度，逼着策略持续铺开试探，这才动到策略那一侧。再往前还有一路把标量 Critic 换成分布式 Critic 的做法，下一节的配方里会用到。这几件零件（双 Q 取小、目标网络软更新、随机抽样、更新采样比）就是 2.5 节死亡三角那笔账要付的工程开销，下一节起会在真实训练里逐个现形。

4 同一个 G1，换 off-policy 再走一遍：15 分钟学会走路

连续动作的 off-policy 讲完了。现在把镜头拉回第 14 讲的老地方 G1 行走，看看业界怎么把同一套 off-policy 规模化：它真能在大规模并行仿真里顶替 on-policy 吗？2025 年恰好有一对工作把这件事做成了标杆。

4.1 FastTD3 与 FastSAC：把 off-policy 搬进大规模并行仿真

off-policy 算法（SAC、TD3）在机器人学界长期被认为“样本效率高但难伺候”，主流的大规模并行仿真训练（第 14 讲那套 4096 环境 + PPO）一直是 on-policy 的天下。**FastTD3**[8] 打破了这个格局：他们发现只要几处关键设计调对，off-policy 完全能在数千个并行环境的规模下稳定训练，而且**更快**。配方简单得出奇：

- 并行采样进同一个 **replay buffer**: 几千个环境同时交互, 所有转移汇入一个大池子——并行仿真的吞吐和经验复用的效率第一次叠加在一起。
- 大 **batch 更新**: 每次从池子里采上万条转移做一步梯度, 充分喂饱 GPU。
- 高更新采样比 (**UTD**): 每采一步环境交互, 做多次梯度更新——on-policy 做不到的“一份数据榨多次”, off-policy 的看家本领。
- 精心调校的稳定性配件: 双 Q 取小、目标网络软更新等 (2.5 节说过, 这些是 off-policy 的必要开销)。

FastTD3 在 HumanoidBench 等人形基准上把训练时间压到单张 A100 上三小时以内, 并把学到的策略部署上了 Booster T1 全尺寸人形真机; **FastSAC** 是同一篇工作里把这套配方套在 SAC 上的版本。

4.2 结果: G1 行走, 单卡 15 分钟

后续工作《Learning Sim-to-Real Humanoid Locomotion in 15 Minutes》[9] 把这套配方推到了极致: 在单张 RTX 4090 上, **15 分钟**训出能通过 sim-to-real 部署到 Unitree G1 和 Booster T1 真机的行走策略——训练时还开着强域随机化 (随机动力学、粗糙地形、外力推搡)。下图取自该论文, 上排是训好的策略部署在真机上的照片, 下排是训练曲线。




图 7: FastSAC/FastTD3 与 PPO 在 G1、T1 行走和全身动作跟踪上的回报-墙钟时间曲线 (横轴是墙钟时间, 纵轴是任务回报), 上排为 sim-to-real 部署到真机的画面

曲线的读法: 横轴是**墙钟时间** (不是环境步数), 纵轴是速度跟随任务的回报。左、中两张图里, 蓝线 (FastSAC) 和绿线 (FastTD3) 都在 10 分钟上下冲到平台期, 黑线 (PPO) 到 15 分钟还没停止爬升——G1 那张上它只到两条彩线的四成出头, T1 那张上追到了七成, 差距没那么悬殊。右图是更难的全身动作跟踪 (和第 14 讲 8.2 节那个 BeyondMimic 同类任务), 时间尺度拉长到 600 分钟——这里要看仔细: **只有 FastSAC 全程领先**, FastTD3 前期虽快, 约 350 分钟后被 PPO 反超、最终收在它

下面。所以 off-policy 的墙钟优势在长时间尺度上并非无条件成立，换个算法就可能翻盘。

备注：这是同一块 GPU 上的墙钟对比，不是“PPO 学不会”——给足时间 PPO 也能到平台。off-policy 每一步更新更重（大 batch、多次梯度），但样本复用让它总体上快得多。另外论文用了**极简奖励函数**——off-policy 对奖励设计的品味和 on-policy 不完全一样，把第 14 讲的奖励原样搬过来不一定最优。

这个结果和第 14 讲形成了一组干净的对照：**同一台 G1、同一类行走任务**，第 14 讲的 PPO 靠 4096 个环境堆出上亿步交互，这里的 FastSAC 靠“每条经验反复用”把墙钟压缩到一刻钟。第 14 讲埋的“为什么真机要换 off-policy”，在仿真里就已经初见分晓。

4.3 动手实验：给 G1 行走加第四个版本

第 14 讲的 G1 行走模块里躺着三个训练脚本：`code/rl/1_rl_basics/1_1_g1_walk_rl/train_v1_reinforce.py`、`code/rl/1_rl_basics/1_1_g1_walk_rl/train_v2_a2c.py`、`code/rl/1_rl_basics/1_1_g1_walk_rl/train_v3_ppo.py`——同一个任务，算法由简到繁。这里再补一个动手实验：给第 14 讲这条 G1 阶梯加**第四级**——off-policy 的 SAC 版本，环境、奖励、模型骨架全部复用，只换算法。

实验设计如下：

- **任务与环境**：与第 14 讲完全相同的 mjlab G1 平地速度跟随环境（G1WalkEnv），不改任何奖励项——保证对照干净。
- **代码结构**：和 v1 到 v3 一样的 Lightning 四件套。最有教学价值的差异在数据层：前三个版本用的是 G1WalkRolloutDataset，每轮在线采一段新 rollout；SAC 版本换成 G1WalkReplayDataset——转移存进池子、随机抽样训练。**on-policy 和 off-policy 的全部区别，在数据这一层直接看得见。**
- **训练配方**：取 FastSAC 配方中对课堂有意义的三件——并行环境采样进同一个 buffer、大 batch、高 UTD；分布式 Critic 等纯提速细节不进这个 G1 版本，保持代码能一口气读懂。
- **对照口径**：两张曲线图。第一张按**环境步数**对齐——预期 off-policy 在早期样本效率上显著占优，这是“每条经验反复用”的直接兑现；第二张按**墙钟时间**对齐——诚实展示 off-policy 每步更新更贵的另一面。最后配 rollout 视频对照步态质量。

这套实验已经落进课程代码仓：`code/rl/1_rl_basics/1_1_g1_walk_rl/train_v4_sac.py`，与前三个版本并排摆放；评测数字、对照曲线与 rollout 视频在 `code/rl/1_rl_basics/result/1_1_g1_walk_rl/` 里（`compare.json` 是逐档评测的原始记录）。下面按结果读图。

先回答最要紧的问题：它会不会走？会。取第 900 次迭代那份存档做确定性评测（256 个环境各跑 300 步），摔倒率 0.96%，抽帧里能看到真实的迈步——不是站桩，也不是高频抽搐。但平均 reward 只有 0.026，是 v3 PPO 峰值（0.098）的四分之一出头。

再看两张对照曲线。第一张按环境步数对齐：SAC 的第一个存档点（246 万步）就已经在 0.026，而 PPO 的第一个存档点要到 2000 万步（当时 0.064）。要小心的是，2000 万步之前 PPO 没有存档，两




图 8: SAC 版本的 rollout 抽帧，G1 在速度指令下持续行走、全程保持直立。四格取自 G1 行走模块 result 目录下的 rollout 视频 g1-walk-sac.mp4

条曲线的“交叉点”并没有实测——所以这张图只支持一个定性结论：**off-policy 在起步阶段确实更省交互**，不支持“省了多少倍”这样的定量说法。第二张按墙钟对齐：同样跑满 3000 次迭代，SAC 用了约 15 分钟，PPO 约 103 分钟。




图 9: 按环境步数对齐的 reward 曲线（横轴对数刻度）：SAC 整段曲线都落在图的左侧，最高点就在最早的存档点（246 万步、0.026），此后总体下行、中途数次回升；PPO 的第一个存档点要到 2000 万步，此后一路爬到 0.098 的平台。数据来源是 G1 行走模块 result 目录下的 compare.json

但这两条曲线还告诉你一件更要紧的事：**SAC 这条是往下走的**。记录里 SAC 每 300 次迭代存一档，十档的 reward 依次是 0.026、0.025、0.026、0.018、0.011、0.017、0.013、0.018、0.006、0.012——**最高点就是最早那一档**，第 2700 次迭代那档只剩 0.006，不到峰值的四分之一；同期摔倒率也从 0.96% 抬到 1.0%~1.4% 之间起伏。也就是说，我们拿去评测的 0.026 是在**第 4 分钟**挣到的，后面那十来分钟训练不但没让它变好，还把它训坏了。

这恰恰是 2.5 节死亡三角那笔账的现场：函数近似、自举、离策略数据三者凑齐，训练就失去了“只会




图 10: 按墙钟时间对齐的 reward 曲线，横轴换成训练用掉的分钟数，两条线仍是 SAC 与 PPO：跑满 3000 次迭代，SAC 约 15 分钟、PPO 约 103 分钟；SAC 那条从第一个存档点（约 1.3 分钟）起就是全程最高，剩下的十几分钟一路往下走

越来越好”的保证——on-policy 那边“数据永远新鲜、错账很快被重访修正”的兜底没有了。至于这一次具体坏在哪一条边上，我们没有做到定位（要盯 α 、Q 值量级、动作幅度逐项回放），所以这里只报形状不报病因。对读者的实操含义很直接：**off-policy 训练必须存档并逐档评测，不能训完直接取最后一档**——最后一档很可能不是最好那一档。

版本	算法	类别	最好的一档 reward	该档摔倒率	该档交互量	该档墙钟	跑满 3000 迭代总 墙钟
v3	PPO	on-policy	0.098	0%	2.16 亿步	约 76 分钟	约 103 分钟
v4	SAC	off-policy	0.026	约 1%	246 万步	约 1.3 分钟	约 15 分钟

（表里 v4 那一行取的是峰值档；正文和抽帧用的是第 900 次迭代那份存档，reward 同为 0.026、摔倒率 0.96%、交互量 737 万步、墙钟 4.1 分钟——两档成绩在评测噪声内，取哪一档结论都一样。）

为什么没追上 PPO 的平台？两个原因，4.2 节的备注其实都预告过：这套奖励本来是给 PPO 调的，off-policy 的品味不一样；而且课堂版刻意只保留 SAC 最核心的零件，论文配方里的分布式 Critic（3.4 节那一套）和逐任务精调过的整套超参都没上——它们正是论文里绝对性能的来源。所以这张对照图

的正确读法不是“SAC 不行”，而是：**样本效率与绝对性能是一对要靠配方去调和的矛盾**——起步省交互是 off-policy 结构性的优势，绝对高度则要靠完整配方去挣。

同样要说清楚的是，**这个 15 分钟和 4.2 节论文那个 15 分钟不是一回事**：论文的一刻钟练出的是能 sim-to-real 上真机的行走策略，我们这一刻钟练出的是一个 reward 只有 PPO 四分之一、而且后半程还在退化的策略。两者唯一可比的是“off-policy 在这个量级的墙钟里确实能把腿迈起来”，不是成绩。

跑通之前先踩了三个坑，每一个都是第 3 节讲过的零件在真实训练里的反面教材，值得记下来：

1. **奖励尺度**。G1 每步 reward 只有 0.05 上下，直接进 SAC 的目标会被熵项整个淹没——actor 优化的全是“保持随机”，机器人永远站着不动。把 reward 放大十倍之后，任务信号才压得过熵。回头看 3.3 节的目标函数：reward 和熵是相加的两项，谁的量级大谁说了算。
2. **温度失守**。自动温度（3.3 节的第四个零件）会自己往下调 α ，训到后期 α 掉到 0.01 附近，熵正则实际上消失，策略开始把动作越顶越大、步态反而退化。解法是给 α 设一个 0.1 的下限——自动温度照常工作，但不许它把探索完全关掉。
3. **动作幅度**。tanh 挤压的输出上限一开始设成 3.0，策略学出灾难性的大幅甩动；收回 1.0（这个环境的动作本来就是 1 上下的量级）才回到正常步态。

三个坑合起来是一句话：**off-policy 的稳定性从来不是白来的**——同一份代码，几个数值不对就完全不收敛。这也为第 5 节埋下伏笔：真机方案要在 SAC 之上再垫示教、干预这么多层保险，正是因为它在真机上连“重训一次试试”的机会都没有。

4.4 本节小结

本节用 FastTD3/FastSAC 回答了“off-policy 行不行”：不但行，在大规模并行仿真里还更快——单卡 15 分钟训出能上 G1 真机的行走策略，核心配方是并行采样进同一个 replay buffer、大 batch、高 UTD。我们自己的第四版动手实验印证了这条路的两面：起步省交互、墙钟压到一刻钟是结构性的，绝对高度则要靠完整配方去挣。它的局限也要看清：这仍然是**仿真里的胜利**，奖励函数是白拿的、复位是免费的、探索撞坏了按 R 重来。下一节把这三张“仿真特权卡”全部收走，看看真机上还缺什么。

5 真机压轴：HIL-SERL 让 SO-101 学会接触型任务

到这里，off-policy 在仿真里已经走通了：连续动作有 SAC，规模化有上一节那套配方。但那仍是**仿真里的胜利**——奖励是白拿的、复位是免费的、探索撞坏了按 R 重来。这一节把这三张“仿真特权卡”全部收走，看看真机上还缺什么，再用一整套工程答案把它补齐。好消息是不用从头造轮子：这套答案叫 **HIL-SERL**[10]，而且已经被 LeRobot[11] 官方移植到 SO-100/SO-101——第 9 讲 4.1 节采数据用的那套 Leader-Follower 臂，现在原封不动就能变成一套真机强化学习装备。所以这一节采取“**概念一件、操作一件**”的走法：每讲清 HIL-SERL 的一个部件，紧接着就给出它在 LeRobot 里对应的那一步命令。

5.1 把 SAC 搬上真机：四道坎

把第 3 节那个 SAC 直接搬上一台真实机械臂，会立刻撞上四道坎：

1. **奖励谁来发？** 仿真器里 reward 是一行代码，因为仿真器知道每个物体的真实位姿。真机上没有上帝视角——“插头插进去了没有”，只有相机看得见。
2. **谁来复位？** 仿真里回合结束一键 reset。真机上方块掉在地上不会自己飞回桌面。
3. **探索会闯祸。** 随机初始化的策略在真机上乱抡，轻则任务毫无进展，重则撞坏夹具和工件。
4. **样本贵上加贵。** 第 1 节算过的账，在接触型任务上更严苛——插拔、对位这类任务容错以毫米计，瞎探索几乎撞不出成功，稀疏奖励长期是零，学习根本启动不了。

HIL-SERL (Human-in-the-Loop Sample-Efficient Robotic Reinforcement Learning, 人在环的样本高效机器人强化学习, UC Berkeley) [10] 就是针对这四道坎给出的一整套工程答案，2024 年放出预印本，2025 年发表在 Science Robotics 上。它不发明新算法，而是把一条成熟的 off-policy 血缘链带上真机，再补上“人”这个要素。

5.2 一条血缘链：SAC 到 HIL-SERL

HIL-SERL 不是凭空出现的，它是伯克利同一条线上四步演进的终点，每一步只解决一个问题：

工作	年份	在前一步上补了什么
SAC[6]	2018	连续动作 off-policy 的算法底座（第 3 节）
RLPD[12]	2023	先验数据进池子 ：每个 batch 一半采自在线经验、一半采自离线示教；配上高 UTD 和 LayerNorm 稳住 critic
SERL[13]	2024	软件套件 ：actor 与 learner 分进程解耦、阻抗控制器保护硬件、免复位训练支持
HIL-SERL[10]	2024	人在环 ：训练中人工干预 + 视觉奖励分类器，通吃接触型任务

链条中间的 **RLPD** (RL with Prior Data) 值得多说两句，因为 HIL-SERL 的 learner 跑的就是它。它对 SAC 只做三处改动，每处都对着一个真机痛点：

- **对半采样**：每个训练 batch 一半抽自在线经验池、一半抽自示教池。比例焊死在五五开是刻意的——全吃示教会过拟合到“学得像”（那是模仿学习的地界），全吃在线经验又回到冷启动的老问题；对半保证每一步更新既有“成功长什么样”的锚，又有“我自己刚犯的错”的新鲜教训。
- **高 UTD**：每采一步做多次梯度更新（2.5 节说的 UTD 杠杆），把真机上贵得要命的每条转移榨干。
- **critic 加 LayerNorm**：高 UTD 会放大死亡三角的风险，尤其是 critic 对**没见过的动作**报出离谱高分、被 actor 钻空子的问题；LayerNorm 把网络输出的量级压住，是让“猛榨样本”不翻车的关键配平。

记住这条链的读法：**SAC 给能力，RLPD 给样本效率，SERL 给工程骨架，HIL-SERL 给真机落地的最后一公里。**

下面就把 HIL-SERL 拆成“四件套 + actor-learner 架构”逐个讲透——每讲完一件，紧接着给出它在 LeRobot SO-101 上对应的那一步操作。

5.3 落到我们的硬件：角色分工与第一步——划安全边界

先把任务和硬件摆好。**任务**选接触型的入门款：**把方块推到目标区域** (push cube to goal region)。它具备接触任务的全部要素——推的力道和角度直接决定成败、视觉可判定成功——又足够短 (5 到 10 秒一个回合)，符合 HIL-SERL 的甜区。练顺之后可以升级到抓取-提起 (pick and lift)。

硬件分工和第 9 讲 4.1 节遥操作采数据时一模一样，但角色变了：

- **follower 臂**：不再重放人的动作，而是作为 **RL actor 的身体**，执行策略输出的动作、与环境真实交互。
- **leader 臂**：不再全程主导，而是作为**人的干预接口**——训练中它实时跟随 follower 的姿态，人随时可以握住它接管几步 (SO-101 leader 的减速齿轮让“顺滑接管”成为可能)，键盘 space 键在“策略控制”和“人控制”之间切换。
- **两路相机** (顶视 + 腕视)：既是策略的眼睛，也是奖励分类器的裁判席。

动作空间有一个关键选择：**在末端执行器 (EE) 空间学，不在关节空间学**。策略输出的是末端的 x、y、z 位移增量，由逆运动学换算成关关节目标。经验上，操作类任务在关节空间学 RL 要难得多——同样的任务换到 EE 空间往往才变得可学；而且 EE 空间里“划安全边界”直观得多。

这条 EE 边界正是 5.1 节第三道坎 (探索会闯祸) 的第一个工程回应，也是全流程的第一步操作。运行 `lerobot-find-joint-limits`，手动拖着 follower 把“完成任务需要的空间”扫一遍，脚本记录末端位置的最小、最大值：

```
lerobot-find-joint-limits \  
  --robot.type=so101_follower --robot.port=/dev/ttyFollower \  
  --teleop.type=so101_leader --teleop.port=/dev/ttyLeader
```

得到的边界写进配置的 `end_effector_bounds`。这一步同时回应了两件事：探索安全 (策略出不了这个箱子)，和学习难度 (动作空间被压缩到任务相关的一小块)。

5.4 第一件套 demo buffer：示教打底，并采下示教

概念。训练开始前，先用遥操作采一批成功示教，装进一个独立的 **demo buffer**。这直接继承 RLPD：每个训练 batch 一半来自在线经验池、一半来自示教池——从第一次梯度更新起，网络就见过“成功长什么样”，不必从纯随机探索里大海捞针。这是对第四道坎 (学习启动不了) 的回答。

操作。在 LeRobot 里，把配置文件 `mode` 设为“record”，用 leader 遥操作采 **15 到 20 条成功示教** (论文里典型是 20 到 30 条)：

```
python -m lerobot.rl.gym_manipulator --config_path env_config_so101.json
```

每条示教以人按下“成功”键结束（该回合最后一步记奖励 1）。数据落成标准 LeRobot 数据集——第 9 讲 3.3 节学的那套数据格式，在这里原样复用。

5.5 第二件套视觉奖励分类器：让相机当裁判，并把它训出来

概念。不手写奖励函数，也不让人逐帧打分，而是把“成功了吗”学出来：遥操作采集一批正样本（任务完成的画面）和负样本（没完成的画面）——论文的典型配比是约 200 正、1000 负，折合十来条轨迹、五分钟的事——训练一个基于 ResNet 的二分类器。训练时它盯着相机画面，输出 0/1 稀疏奖励，还顺带自动判断回合结束。这是对第一道坎（真机没有上帝视角）的回答。

备注：分类器也会被骗——机械臂挡住目标、光照变化都可能造成误判。假阳性尤其危险：策略会学会“摆拍”骗分。实践中靠提高判定阈值、追加难负样本来修，这也是下面训练分类器时要专门留心的点。

操作（一）：先框视觉关注区。RL 直接从像素学习，对背景干扰极其敏感——光照变化、路过的人、工作区外的杂物都可能把学习带偏。上分类器之前，先用交互工具把每路相机的画面裁到任务核心区：

```
python -m lerobot.rl.crop_dataset_roi --repo-id < 你的示教数据集 >
```

框出的裁剪参数写进配置的 `crop_params_dict`，图像统一缩放到 128×128 。

操作（二）：训练分类器。先把 `terminate_on_success` 设为 `false` 再采一批数据——回合在成功后不立即截断，让“成功状态”的画面多攒一些（正样本不足是分类器最常见的坑）；然后用 ResNet-10 底座训二分类器：

```
lerobot-train --config_path reward_classifier_train_config.json
```

训完把模型路径写进配置的 `reward_classifier.pretrained_path`，判定阈值从 0.7 左右起调。上真机前先单独测一轮：故意摆几个“像成功但不是”的场面，看它会不会误判。

5.6 第三、四件套人工干预与自动复位

人工干预（第三件套）。这是 HIL-SERL 名字里“Human-in-the-Loop”的本体。在线训练时人守在旁边，看到策略快要闯祸或卡死，随时接管遥操几步把机器人带回正轨，然后把控制权还给策略。关键在于干预数据的用法：接管的那几步被当作高质量的 off-policy 转移，照常存进经验池参与训练——2.1 节说过，off-policy 不挑数据来源，人的手就是另一个行为策略。

这与模仿学习里的 DAgger 家族形成一组重要对照：HG-DAgger[14] 同样让人纠偏，但把纠偏数据拿去做监督学习——策略的上限被钉死在“学得像示范者”；HIL-SERL 把同样的数据交给强化学习——干

预只是引路，策略最终按任务奖励自我优化，可以**超过**示范者（5.8 节与 HG-Dagger 的对照曲线会印证这一点）。这是对第三道坎（探索闯祸）的回答：人挡住最坏情况，策略保留自我提升空间。这一件套的操作接口就是 5.3 节说的 leader 臂 + space 键，具体命令并进下一节的在线训练里一起给。

自动复位（第四件套）。回合结束后环境自动回到初始分布：SERL 提供了 forward-backward 双控制器的免复位方案（一个策略做任务、一个策略负责“拆回去”），SO-101 这类简单场景则用固定复位关节位加随机化初始姿态。人只负责偶尔把掉落的物体捡回工作区。这是对第二道坎（谁来复位）的回答。

5.7 actor-learner 架构：拼成在线系统，并跑起来

四件套怎么拼成一个在线系统？下图是 HIL-SERL 论文的系统总览。




图 11: HIL-SERL 系统架构: actor 进程与环境实时交互并接受人工干预, learner 进程从双 replay buffer 采样更新, 两者异步通信

按数据流走一遍这张图：

- **左边 actor 进程：**以 10 Hz 的固定节奏和环境交互。每一拍，环境给出观测 s （相机图像 + 本体状态），动作要么来自 RL 策略 (a_{RL})，要么来自人的干预 (a_{itv} ，虚线路径)——谁在控制就听谁的。二值奖励分类器在环境侧充当裁判。时间轴上蓝色段是策略自主，黄色段是人接管。
- **learner 里的 replay buffers：**两个池子。RL buffer 收在线转移，demo buffer 装训练前采的示范；learner 每个 batch 从两池对半采样（RLPD 的规矩）。注意图上**两个池子的底部都画着一层 Interventions**——人接管的那几步既算在线经验、也算示范，两边都进，这是它比普通 RLPD

多出来的一笔。

- **右边 learner 进程**：在 GPU 上闷头做梯度更新（actor 网络 + critic 网络），周期性把刚更新好的策略参数推回 actor 进程。
- **右上网络结构**：多路相机图像过同一个预训练 ResNet-10 编码，与本体状态编码拼接后进 MLP。

actor 和 learner **异步解耦**是真机 RL 的硬需求，不是花活：真机控制必须踩着 10 Hz 的实时节拍，不能停下来等 GPU 算完一个 batch；反过来 GPU 也不该在机器人慢吞吞动作时闲着。分进程后两边各按各自的节奏满负荷运转，这个设计在下面的 LeRobot 实现里原样保留。

LeRobot 把整套 HIL-SERL 封装成三块：环境侧的 `gym_manipulator`（把真机包成 Gym 风格环境，串起奖励分类器、干预、安全边界等处理管线）、训练侧的 `lerobot.rl.learner` 与 `lerobot.rl.actor` 两个进程入口（正对上面架构图的两个进程），以及一份 JSON 配置文件贯穿全部环节——工程实现与上面那张论文架构图一一对应。

操作：起两个进程做在线训练。边界、示教、分类器都就位后，两个终端分别拉起两个进程，人守在 leader 旁边：

```
python -m lerobot.rl.learner --config_path train_config_hilserl_so101.json
python -m lerobot.rl.actor   --config_path train_config_hilserl_so101.json
```

干预的节奏是门手艺，官方与论文的经验一致：**开头几个回合先让策略自由探索摸清行情**；之后**短促、精准地**接管——策略卡死或将要出界时拉一把就还权，不要长时间代驾；策略开始能完成任务后，把干预收缩到“临门一脚”级别的小修正。

备注：三个对成败影响最大的超参——

- `temperature_init`：SAC 初始温度，从 0.01 量级起步；设太高会让干预“教不进去”。
- `policy_parameters_push_frequency`：learner 向 actor 推送参数的间隔，压到 1 到 2 秒，让 actor 总用上新鲜策略。
- `storage_device`：设为 cuda，省去参数在 CPU、GPU 间搬运的开销。

收口：评测。训练前后各跑 20 个回合测成功率（训练前用纯示教做基准），配上训练全程的干预率曲线与回报曲线，就构成这次实验的完整证据链。

5.8 训练全景与真机战绩

把四件套按序上场串起来，就是 HIL-SERL 的一次完整训练，下图（同样取自论文）画的就是这三步。

左上：遥操采正负样本，训出二值奖励分类器。左下：遥操采 20 到 30 条示教进 demo buffer。右侧：在线训练——策略与环境交互，分类器发奖励。右侧那一叠横条是按时间排开的一个个回合，**时间轴自下而上**（图右侧那个大箭头标着 Training Time）：底下几行早期回合里橙色的人工干预段又多又长，末尾还常是红色的失败标记；越往上橙色越稀、蓝色的策略自主段越连成整条，末尾的绿色成功标记越来越密。




图 12: HIL-SERL 训练流程：先遥操采正负样本训练奖励分类器，再采集示教装入 demo buffer，最后在线训练并逐步减少人工干预

论文在七类真机任务上验证了这套流程（结果表把它们按子任务拆成 13 行）：主板装配（内存条插入、SSD、USB 插拔与理线这类精密插拔）、宜家板件装配、汽车仪表盘装配、物体交接、传动带装配、抽积木、平底锅翻物——精密装配、动态操作、双臂协作都在里面：

实验结果压成三条即可带走：

1. **1 到 2.5 小时的真机训练**就能把几乎所有任务练到 100% 成功率——这是“真机 RL 不可行”这个旧共识被打破的核心数字。
2. 相对模仿学习基线，平均成功率约 **2 倍**，执行速度快约 **1.8 倍**——RL 不只是学会了，还在按任务目标持续优化动作质量。
3. **干预率一路降到 0**——人从“全程陪练”逐渐退成“旁观者”，这是系统在自我提升的最直接体征。要注意降的过程并不平顺（5.10 节会看到一条真实曲线中途还会回升），能指望的是趋势，不是单调。

上图的对照值得细看，而且**要一行一行看，不能只看第一行**。

成功率那一行（第一行）里，两者的差距只在难任务上明显：内存条插入上 HG-Dagger 一路掉到 0、USB 从 0.9 滑到 0.65，而 HIL-SERL 都爬到了 1.0；可到了宜家顶板和汽车仪表盘这两个相对好做的任务上，HG-Dagger 也爬到了 0.89 和 0.97，跟 HIL-SERL 差不了多少。**光看成功率，会低估这组对照的信息量**。

真正干净的分界线在第二行**干预率**：HIL-SERL 的四条粉线全部降到 0 并留在那里，而 HG-Dagger 的青虚线在四个任务里有三个后期不降反升——策略越训，人越得频繁伸手。第三行**单次耗时**大体是同一个故事，但要老实留下一个反例：HIL-SERL 四条全在下降；HG-Dagger 在内存条（7.6 秒升到 8.4



图 13: HIL-SERL 论文中的部分真机任务：抽积木、平底锅翻物、传动带装配、仪表盘装配、内存条插入、双臂搬桌板

秒) 和 USB (9.3 升到 10.7) 上不降反升, 宜家顶板中途冲高到 8.6 又回落到 7.0、基本原地踏步, **只有汽车仪表盘确有改善——从 16.5 秒降到 12.2 秒, 快了约四分之一**。可这一档恰恰是它干预率升得最凶的一档 (0.16 一路涨到 0.59) ——这点提速是拿干预换来的。

也就是说, 即使在 HG-DAGGER 成功率追平的那两个任务上, 它也是靠人一直在旁边托着才追平的。同样的人力投入, 监督学习“吸收”干预、把它变成更像示范者的模仿, 强化学习“消化”干预、把它变成自己不再需要人的能力——差距就在这。

局限性也要摊开: 每个任务都要**单独**走一遍全流程 (没有跨任务泛化, 这正是 VLA 那条线擅长的事); 任务时长以 5 到 10 秒的短程为主; 奖励分类器可能被骗。这些边界划出了它和前几讲方法的分工——本讲第 6 节会回到这张分工地图。




图 14: HIL-SERL 与 HG-Dagger 在四个任务上的对照：成功率、干预率与单次执行耗时随训练时间的变化

5.9 没有真机：gym_hil 仿真替代

没有 SO-101 也能完整体验这套流程。LeRobot 配套的 `gym_hil` 提供了 MuJoCo 版的 Franka Panda 抓方块环境，键盘或手柄充当干预接口：

```
# 配置里 task 设为 PandaPickCubeKeyboard-v0，其余流程与真机完全一致
python -m lerobot.rl.actor --config_path train_gym_hil_env.json
python -m lerobot.rl.learner --config_path train_gym_hil_env.json
```

采示教、起两个进程、space 接管干预——和真机同一套命令与配置结构。仿真里有物体真值，奖励可以直接判，四件套里的“奖励分类器”这一件在仿真里是可选项。建议的学习路径：先在 `gym_hil` 里把全流程跑熟，再上真机——真机上每一分钟都贵，别把学工具的成本花在真机时间里。

这张有无干预的对照图说明的是另一件事——干预对**学习速度**的贡献：

橙色那条（无干预）在头一万八千步里贴着 0 一动不动，之后才开始爬，到三万步上下才追平；有人干预的两条（粉、绿）不到一万步就已接近满分、曲线在那里就结束了——**有干预的两次都在一万步内到顶，无干预那次要到三万步上下**。这一组每种条件各只跑了一次，量级参考即可，不宜再往下乘出倍数。方向是清楚的：干预不是锦上添花，而是真机 RL 能在小时级完成的关键。




图 15: 人工干预对学习速度的影响：三条 episodic reward 曲线里，无干预那次（橙）到约 3 万交互步才追上最高回报，有人干预的两次（粉、绿）在 1 万步以内就到顶。图例三条都写作 `default`，哪条对应哪次实验依 LeRobot 官方文档的说明判定

5.10 训练健康的体征：盯着干预率

在线训练阶段最值得盯的一张图不是回报曲线，而是**干预率曲线**。下面这张图来自 LeRobot 官方文档的抓取-提起实验。

这是“健康训练”的模样：**总体趋势向下**。注意它并不单调——3.3k 步附近先归零，接着又回升到 0.3 上下、最高约 0.4，拉锯了近一千步，最后才真正稳定在 0。真机训练很少给你一条干净的下降曲线；要盯的是趋势，不是某一段。如果训练半小时干预率还纹丝不动，通常说明出了问题（奖励分类器误判、边界设错、或干预方式太“代驾”），该停下来排查而不是继续耗真机时间。

需要说清楚的是：这一节给的是一条**照着能走通的流程**，不是我们自己跑完的一次实验——上面所有数字和曲线都来自 HIL-SERL 论文与 LeRobot 官方文档。你在自己那台 SO-101 上按 5.3 到 5.7 走完一遍，拿到的训练前后成功率对照、干预率曲线和 rollout 视频，就是属于你自己的那份证据链。

5.11 本节小结

本节把 HIL-SERL 从概念一路落到我们自己的硬件上。它把“真机稀疏奖励 RL 学不动”拆成四道坎，用四件套逐一回应：示教打底解决冷启动、视觉奖励分类器解决没有上帝视角、人工干预解决探索闯祸、自动复位解决连续训练；底座是 SAC 到 RLPD 到 SERL 的 off-policy 血缘链，架构上 actor 与 learner 异步解耦保住真机的实时节拍。落到 SO-101 上，每个部件都对应 LeRobot 里的一步操作——划安全边界、采示教、框 ROI、训分类器、双进程在线训练、评测收口，每一步都是第 9 讲数据工具链的自




图 16: 一次健康训练的干预率曲线：从 0.5 上下的高位总体下行，3.3k 步附近一度归零；随后有一段回升到 0.3 上下、最高约 0.4，并持续约一千步，4.7k 步后才稳定归零（截图自 LeRobot 官方文档）

然延伸；没有真机就用 gym_hil 走完全流程。战绩：1 到 2.5 小时真机训练做到接近 100% 成功率，约 2 倍于模仿基线；训练健康与否，第一看干预率是否持续下降。局限：单任务、短程、分类器可被骗，且真机训练全程需要人值守。它的一切素材——旧经验、示教、干预——之所以能进同一个池子，全靠 off-policy 不挑数据来源这一条根性质。

6 结课全景：三种强化学习，与一条完整的链路

6.1 三种 RL 形态对照

课程的强化学习三部曲到此收官。三讲各用了一种形态的 RL，放进一张表里，差异一目了然：

	第 14 讲	第 15 讲	第 16 讲
载体	G1 人形行走/动作跟随	VLM 数数（动手）、VLA 操作（导读）	SO-101 接触任务
训练地点	仿真（大规模并行）	仿真 rollout / GPU 答题	真机在线
动作	连续关节控制	离散 token	连续 EE 控制
奖励	手写密集奖励	可验证规则，稀疏但免费	学出来的视觉 0/1
数据方式	on-policy	on-policy	off-policy
critic	有（GAE 基线）	无（组内相对优势）	有（Q 函数，主角）
人的角色	写奖励函数	写判分规则	示教 + 在线干预
代表算法	PPO	GRPO	SAC (RLPD/HIL-SERL)
本讲演示阶梯	REINFORCE→A2C→PPO 单一 GRPO		表格 Q→DQN (CartPole) + SAC (G1 第四版)

这张表也是一张**选型地图**：有仿真、能并行、奖励好写——on-policy 大力出奇迹（第 14 讲）；策略本体是生成模型、结果可规则验证——GRPO 后训练（第 15 讲）；必须在真机上学、样本以秒计费——off-policy 加人在环（本讲）。三种形态没有高下，只有场景匹配。

6.2 从第 8 讲到第 16 讲：一条链路

把镜头拉远，这九讲其实只讲了一件事——**一台机器人怎么从零获得并持续改进一个技能**：

- **第 8 讲**立了骨架：端到端 policy，观测进、动作出，rollout 才是唯一的裁判。
- **第 9 讲**解决原料：遥操作采集、LeRobot 数据闭环——今天它的 Leader-Follower 臂和数据格式在 RL 里原样复用。
- **第 10 讲**给了第一批可用的大脑：ACT、Diffusion Policy、Flow Matching，模仿学习把示教“学得像”。
- **第 11 到 13 讲**把大脑换成通才：VLA 家族——预训练带来语言理解与跨任务泛化，微调把它对齐到你的机器人。
- **第 14 讲**引入第二种学习范式：不再模仿，而是试错——策略梯度到 PPO，在仿真里大规模练。
- **第 15 讲**把两条线接起来：RL 作为后训练外环，让模仿学出来的 VLA 自我提升。
- **本讲**走完最后一公里：off-policy 加人在环，让学习直接发生在真机上——模仿给底子，人保驾，RL 超越示范者。

模仿学习与强化学习在这条链路上不是对手而是接力：**示教决定起点，试错决定上限，真机决定成色**。课程后续将继续走向世界模型等更前沿的方向，而无论模型形态怎么变，这条“数据-策略-改进”的闭环都是底层不变的骨架。

7 本讲小结

7.1 主线回顾

这一讲从一笔账出发：真机上样本贵三个数量级，on-policy“采完即弃”的奢侈打法玩不起，于是换 off-policy——行为策略与目标策略解耦，旧经验、示教、干预统统进 replay buffer 反复用；数学根基是贝尔曼等式不挑数据来源。我们先在 CartPole 上把 Q 函数、经验回放、目标网络跑成代码，从手工分桶的表格 Q 走到吃原始状态的 DQN。随后把 off-policy 推进到连续动作：DDPG 用确定性 Actor 直接吐动作，代价是单 Critic 高估；TD3 用双 Critic 取小治住高估，却仍卡在探索；SAC 把最大熵写进训练目标，才动到策略那一侧。再往前还有一路把标量 Critic 换成分布式的做法。接着回到 G1 行走验证规模化：FastSAC/FastTD3 单卡 15 分钟练成能上真机的行走。最后 HIL-SERL 把 off-policy 带上真机——示教打底、视觉分类器发奖、人在环纠偏、自动复位撑连续训练，1 到 2.5 小时把接触型任务练到接近 100%，落到 SO-101 上就是一整套 LeRobot 工作流，干预率下降就是训练健康的体征。

7.2 方法演进链

这一讲织了两条演进链。一条是**算法阶梯**，每一级只补上一级的一个短板：

表格 Q $\rightarrow$ DQN $\rightarrow$ DDPG $\rightarrow$ TD3 $\rightarrow$ SAC

分桶到函数近似、离散到连续、单 Critic 到双 Critic、外加噪声到最大熵——一步一个知识点。另一条是把 SAC 带上真机的**工程血缘链**：

SAC $\rightarrow$ RLPD $\rightarrow$ SERL $\rightarrow$ HIL-SERL

能力、样本效率、工程骨架、真机落地——每一步只加一块砖。旁支上，FastTD3/FastSAC 证明同一套 off-policy 底座在大规模并行仿真里同样占优。

一句话总结：真机上的强化学习是一门“省”的艺术——off-policy 把每条经验用到极致，人在环把每次失败挡在损失之外，从 CartPole 一路爬到 SAC 再到 HIL-SERL，讲的都是同一件事：用最少的真机样本，把一个接触型技能在两小时上下学出来。

参考文献

[1] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533. <https://doi.org/10.1038/nature14236>.

- [2] SIMONINI T, SANSEVIERO O. The Hugging Face deep reinforcement learning course[EB/OL]. (2023)[2026-07-04]. <https://huggingface.co/learn/deep-rl-course>.
- [3] SUTTON R S, BARTO A G. Reinforcement learning: an introduction[M]. 2nd ed. Cambridge: MIT Press, 2018. (“死亡三角” 见该书第 11 章 The Deadly Triad 一节)
- [4] LILICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[EB/OL]. (2015-09-09). <https://arxiv.org/abs/1509.02971>.
- [5] FUJIMOTO S, VAN HOOF H, MEGER D. Addressing function approximation error in actor-critic methods[EB/OL]. (2018-02-26). <https://arxiv.org/abs/1802.09477>.
- [6] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[EB/OL]. (2018-01-04). <https://arxiv.org/abs/1801.01290>.
- [7] BELLEMARE M G, DABNEY W, MUNOS R. A distributional perspective on reinforcement learning[EB/OL]. (2017-07-21). <https://arxiv.org/abs/1707.06887>.
- [8] SEO Y, SFERRAZZA C, GENG H, et al. FastTD3: Simple, fast, and capable reinforcement learning for humanoid control[EB/OL]. (2025-05-28). <https://arxiv.org/abs/2505.22642>.
- [9] SEO Y, SFERRAZZA C, CHEN J, et al. Learning sim-to-real humanoid locomotion in 15 minutes[EB/OL]. (2025-12-01). <https://arxiv.org/abs/2512.01996>.
- [10] LUO J, XU C, WU J, et al. Precise and dexterous robotic manipulation via human-in-the-loop reinforcement learning[J]. Science Robotics, 2025. <https://doi.org/10.1126/scirobotics.ads5033>. 预印本 (2024-10-29): <https://arxiv.org/abs/2410.21845>.
- [11] CADENE R, ALIBERT S, SOARE S, et al. LeRobot: State-of-the-art machine learning for real-world robotics in PyTorch[EB/OL]. <https://github.com/huggingface/lerobot>.
- [12] BALL P J, SMITH L, KOSTRIKOV I, et al. Efficient online reinforcement learning with offline data[EB/OL]. (2023-02-06). <https://arxiv.org/abs/2302.02948>.
- [13] LUO J, HU Z, XU C, et al. SERL: A software suite for sample-efficient robotic reinforcement learning[EB/OL]. (2024-01-29). <https://arxiv.org/abs/2401.16013>.
- [14] KELLY M, SIDRANE C, DRIGGS-CAMPBELL K, et al. HG-Dagger: Interactive imitation learning with human experts[EB/OL]. (2018-10-05). <https://arxiv.org/abs/1810.02890>.